

Facultat Internacional de Comerç i Economia Digital La Salle

Trabajo Final de Máster

Máster Universitario en Ciencia de los Datos / Data Science

Buenas prácticas para mitigar las limitaciones del
entrenamiento federado en comparación con el
aprendizaje centralizado

Alumno

Profesor Ponente

Ivan Betriu Kahlenberg

Oriol Izquierdo Robert

ACTA DEL EXAMEN DEL TRABAJO FINAL DE MÁSTER

Reunido el Tribunal calificador en el día de la fecha, el alumno

Ivan Betriu Kahlenberg

Expuso su Trabajo de Final de Máster, el cual trató sobre el tema siguiente:

**BUENAS PRÁCTICAS PARA MITIGAR LAS LIMITACIONES DEL ENTRENAMIENTO
FEDERADO EN COMPARACIÓN CON EL APRENDIZAJE CENTRALIZADO**

Acabada la exposición y contestadas por parte del alumno las objeciones formuladas por los miembros del tribunal, este valoró el mencionado Trabajo con la calificación de

Barcelona,

VOCAL DEL TRIBUNAL

VOCAL DEL TRIBUNAL

PRESIDENTE DEL TRIBUNAL

ÍNDICE

1. ABSTRACT.....	2
2. INTRODUCCIÓN:	4
3. MARCO TEÓRICO	6
3.1 Estrategia Europea de Datos.....	6
3.1.1 Espacios de datos.....	7
3.1.2 Data Governance Act	9
3.1.3 Data Act.....	14
3.1.4 Entorno tecnológico de los espacios de datos	16
3.2 Estrategia de IA de la Unión europea	21
3.2.1. Gigafábricas	22
3.2.2 Implementación actual	23
3.2.3 Objetivo Estratégico y Escala de Despliegue de la UE.....	23
3.2.4 Modelo de Financiación: Las Alianzas Público-Privadas	24
3.3 Aproximación distribuida de la Inteligencia artificial	25
3.3.1 Fundamentos del aprendizaje automático	25
3.3.2 Algoritmos:.....	27
3.3.3 Centralizado y federado.....	34
3.4 Metodologías de entrenamiento federado.....	37
3.4.1 Metodología en función de la infraestructura	37
3.4.2 Metodología en función de los datos	38
3.4.3 Metodología en función del algoritmo de agregación	39
4. METODOLOGÍA.....	43
4.1 Selección de los conjuntos de datos y preprocesamiento	43
4.2 Entorno de desarrollo:	44
4.3 Simulaciones:.....	45
5. ANÁLISIS DE RESULTADOS.....	50
6. CONSIDERACIONES ÉTICAS.....	61
7. DISCUSIÓN.....	63
8. PLAN DE TRABAJO Y COSTE ECONÓMICO	65
8.1 Plan de Trabajo	65
8.2 Coste económico.....	66
9. CONCLUSIONES.....	67
10. LÍNEAS DE FUTURO	68
11. BIBLIOGRAFÍA.....	69

1. ABSTRACT

Dada la creciente necesidad de proteger la privacidad de los datos en todo tipo de aplicaciones de aprendizaje automático, esta investigación se centra en comprender los retos del entrenamiento federado en comparación con el entrenamiento centralizado. Para ello, se aborda un problema de clasificación binaria (epilepsia vs no epilepsia) utilizando un dataset de frecuencias cerebrales. Se aplicaron varios algoritmos de aprendizaje automático (MLP, SVM) a ambos tipos de entrenamiento para una comparación exhaustiva.

Dentro del entrenamiento federado, se exploraron dos planteamientos clave: el IDD (independiente e idénticamente distribuido) y el NO-IDD (no independiente e idénticamente distribuido). Los resultados de las simulaciones apuntan a una ligera reducción del rendimiento en ambos escenarios, siendo más pronunciada en el entorno NO-IDD.

Adicionalmente, se demostró que los modelos federados tienen una menor capacidad de generalización, lo que se evidencia en un mayor diferencial entre los resultados de entrenamiento y validación. Este hallazgo sugiere que la reducción en la generalización no se debe únicamente al entorno NO-IDD, sino también a otros elementos inherentes al proceso de entrenamiento federado empleado. En particular, se identificó que el entrenamiento federado genera un sesgo superior en la clase mayoritaria, lo que puede comprometer la fiabilidad del diagnóstico en aplicaciones médicas. Estas conclusiones resaltan la necesidad de desarrollar estrategias de mitigación para estos desafíos con el fin de optimizar el rendimiento y la equidad de los modelos federados en contextos de datos sensibles.

Given the growing need to protect data privacy in all types of machine learning applications, this research focuses on understanding the challenges of federated learning compared to centralized training. To this end, we address a binary classification problem (epilepsy vs. non-epilepsy) using a brain frequency dataset. Various machine learning algorithms (MLP and SVM) were applied to both training types for a comprehensive comparison.

Within federated learning, two key approaches were explored: IDD (independent and identically distributed) and NO-IDD (non-independent and identically distributed). The simulation results indicate a slight reduction in performance in both scenarios, with the decrease being more pronounced in the NO-IDD environment.

Additionally, it was demonstrated that federated models have a lower generalization capacity, as evidenced by a larger gap between training and validation results. This finding suggests that the reduction in generalization is not solely due to the non-IID environment but also to other factors inherent to the federated training process employed. In particular, it was identified that federated training induces a stronger bias toward the majority class, which may compromise the reliability of diagnosis in medical applications. These conclusions highlight the need to develop mitigation strategies to address these challenges in order to optimize the performance and fairness of federated models in sensitive data contexts.

Keywords: Federated Learning, Supervise machine learning, Support Vector Machine, Multi Layer Perceptron, Data Spaces, Data Act, Data Governance Act, NO-IDD, IDD.

2. INTRODUCCIÓN:

En el actual ecosistema digital, el intercambio seguro y eficiente de datos entre organizaciones se ha convertido en un elemento clave para el desarrollo de soluciones innovadoras y sostenibles. En este contexto, la Unión Europea impulsa la creación de espacios de datos (data spaces). Estos espacios de datos son entornos colaborativos en los que distintos actores pueden compartir datos bajo principios comunes de interoperabilidad, confianza, soberanía digital y protección de la privacidad. Son especialmente relevantes en sectores estratégicos como el sanitario, automovilístico o turístico entre otros, donde el acceso a datos valiosos está fragmentado entre múltiples agentes.

El entrenamiento federado emerge como una tecnología prometedora para hacer posible el análisis colaborativo de datos sin necesidad de centralizarlos, lo que lo convierte en una pieza fundamental dentro del ecosistema de los espacios de datos. Este enfoque es de particular interés para la presente investigación, ya que permite llevar a cabo estudios colaborativos entre instituciones que, de otra forma, no podrían ser realizados debido a las restricciones de privacidad y la fragmentación de los datos. Sin embargo, a pesar de su potencial, esta técnica aún presenta importantes retos: desde la asignación óptima de pesos a los modelos locales hasta la adaptación a entornos heterogéneos con diferentes volúmenes, calidad y distribución de datos.

Mi motivación para escoger este proyecto final fue mi interés en entender en profundidad esta tipología de entrenamiento con un enfoque dirigido hacia un cambio de paradigma respecto al uso de datos para la investigación en ciencia de datos. Con un enfoque más centrado en el respeto de los datos personales y empresariales, a la vez que amplía las oportunidades de colaboración entre entidades.

Profundizando en un desarrollo de actualidad y con vista al futuro de la estrategia de datos de la Unión Europea.

Este proyecto tiene como objetivo identificar los principales retos asociados al entrenamiento federado mediante su comparación con el enfoque centralizado

empleando diversos algoritmos de machine learning. También se busca validar el entrenamiento federado como un camino viable para el análisis colaborativo de datos.

El presente trabajo se estructura en cuatro apartados principales: El marco teórico sienta las bases del estudio, profundizando en las políticas de datos de la UE y los avances en aprendizaje federado. La metodología detalla el diseño experimental y la configuración de los experimentos. Posteriormente, el análisis de resultados contrasta las métricas de rendimiento para evidenciar las diferencias entre ambos enfoques. Y el estudio concluye con una síntesis de los hallazgos y una propuesta de futuras líneas de investigación.

3. MARCO TEÓRICO

En la actualidad los datos se han consolidado como un recurso fundamental para la innovación y el desarrollo económico. Su cada vez mayor comercialización y circulación han abierto, sin duda, nuevas oportunidades. Sin embargo, también han traído consigo riesgos importantes en áreas críticas como la privacidad, la concentración de poder y el uso indebido de la información.

Esta realidad exige a la sociedad buscar e implementar respuestas regulatorias y tecnológicas robustas que aseguren un manejo ético y seguro de los datos.

3.1 Estrategia Europea de Datos

La Estrategia Europea de Datos (2021-2027) surge como respuesta a tres retos fundamentales derivados del nuevo contexto tecnológico: la necesidad de aumentar la competitividad europea en la economía del dato, garantizar la soberanía de los datos para individuos y organizaciones, y asegurar la preservación de los valores europeos en el ámbito digital. En este contexto, la creación de los espacios de datos constituye un elemento clave para impulsar la innovación digital y promover un uso seguro y ético de los datos en diversos sectores estratégicos como en la salud, la movilidad, la energía, la agricultura, las finanzas, la administración pública, la educación, el turismo y la manufactura (Comisión Europea, 2023). Esta iniciativa nace por la necesidad de afrontar los desafíos derivados de la fragmentación de datos valiosos entre múltiples actores, así como asegurar el cumplimiento normativo europeo en materia de privacidad y soberanía digital (Comisión Europea, 2023).

Para superar estos retos la Unión Europea ha optado por establecer un nuevo marco legislativo que regule eficazmente el nuevo ecosistema digital, desplegando varias herramientas legislativas, entre las que destacan la Data Act y el Data Governance Act. La Data Act establece los principios y regulaciones específicas sobre el derecho de uso y reutilización de datos, mientras que el Data Governance Act aborda cuestiones relacionadas con el gobierno y la gestión responsable de los datos, como la compraventa, el acceso legítimo y el cumplimiento estricto del Reglamento General de Protección de Datos (GDPR) (Comisión Europea, 2023). Ambas legislaciones

proporcionan un marco normativo sólido destinado a garantizar tanto la privacidad como la autonomía de los individuos y organizaciones respecto a los datos personales y empresariales.

3.1.1 Espacios de datos

Un espacio de datos se define como un ecosistema tecnológico diseñado para facilitar el intercambio seguro, eficiente e interoperable de datos entre entidades públicas o privadas, con el fin de aumentar la competitividad, empoderar a los propietarios de los datos y asegurar el cumplimiento normativo. Estos espacios están regidos por normativas y principios comunes que incluyen la interoperabilidad, la confianza, el control de la propiedad y el acceso a los datos, así como la posibilidad de que los propietarios ejerzan plenamente la soberanía digital sobre ellos (GAIA-X, 2023).

Los espacios de datos persiguen tres objetivos principales:

- **Competitividad en la economía del dato:** Este objetivo se materializa a través de la reducción de barreras para el intercambio de datos, facilitando la creación de un marketplace de productos y servicios de datos. Además, busca garantizar la disponibilidad de datos de calidad mediante el establecimiento de requerimientos definidos específicamente por cada espacio de datos, como por ejemplo una completitud mínima del 90 %, en función de las necesidades sectoriales y operativas este porcentaje puede cambiar. Y se promueve la reducción de costes operativos mediante la estandarización a cuatro niveles:
 - **Legal:** armonización normativa entre los participantes del espacio, garantizando la compatibilidad legal transfronteriza.
 - **Organizativo:** definición clara de roles, procesos y acuerdos de gobernanza que aseguren la coordinación entre entidades.
 - **Semántico/Negocio:** uso de modelos de datos, vocabularios y ontologías compartidas para asegurar una comprensión común de los datos.
 - **Tecnológico:** adopción de estándares abiertos, APIs interoperables y mecanismos comunes de identificación y seguridad.

Esta clasificación sigue el modelo del Marco Europeo de Interoperabilidad (EIF), adoptado y aplicado en los espacios de datos por iniciativas como el Data Spaces Support Centre (DSSC) (Comisión Europea, 2017; DSSC, 2024).

- **Soberanía de los datos en personas físicas y jurídicas:** Para asegurar este principio, se emplean arquitecturas distribuidas en las que los datos permanecen bajo el control de sus propietarios y solo se comparten mediante conectores. Un conector de datos es un componente de software que actúa como interfaz segura entre el sistema interno de una organización y el espacio de datos. Su misión es permitir el intercambio de datos sin centralizar información, manteniendo el control local de los mismos. El conector implementa políticas de uso y acceso que se negocian de manera automática y verificable, garantizando que sólo se comparta aquello autorizado. Además, puede ejecutarse de forma local en la instalación del participante o en la nube, siempre protegiendo el plano de control y no solo el de datos (Gieß et al., 2024). La federación de sistemas, gestionada por un gestor de identidades, delega la responsabilidad en los propios participantes, asegurando que cualquier oferta de productos o servicios basada en datos requiera la consulta y el consentimiento explícito del propietario. Este principio incluye también la posibilidad de revocar permisos o eliminar datos en cualquier momento, reforzando la soberanía digital y el control individual sobre la información (DSSC, 2024).
- **Cumplimiento normativo y auditoría:** Este objetivo se gestiona a través de una clearing house, definido como un intermediario del espacio de datos que proporciona servicios de conciliación y liquidación tanto para transacciones financieras como de datos. Su función es garantizar la trazabilidad, la aplicación de políticas contractuales y regulatorias, así como ofrecer una supervisión neutral que refuerce la confianza y el cumplimiento normativo entre los participantes (DSSC, 2023).

En este contexto, diversas iniciativas europeas han surgido para facilitar la implementación efectiva de los espacios de datos. Entre las que destacan el Data Spaces Support Centre (DSSC), que se encarga de proporcionar orientación técnica y soporte operativo, y GAIA-X, una plataforma europea centrada en la estandarización

tecnológica y en el desarrollo de perfiles profesionales clave para la gestión de estos espacios, como analistas, arquitectos funcionales o responsables de cumplimiento normativo. Además de asegurar una gobernanza efectiva y transparente, promoviendo la cooperación entre empresas, administraciones públicas y centros de investigación para definir protocolos comunes que garanticen el intercambio de datos seguro e interoperable (GAIA-X, 2023).

Dentro de este marco, la integración del método de entrenamiento federado es particularmente relevante en contextos donde la soberanía y privacidad de los datos son esenciales. Por el contrario, el aprendizaje centralizado o no federado, resulta más adecuado cuando se prioriza la potencia computacional y no existen restricciones significativas respecto al intercambio de datos sensibles.

En este sentido, los espacios de datos constituyen un componente esencial para la construcción de una infraestructura digital europea sólida, colaborativa y centrada en el ciudadano. Su consolidación puede favorecer no solo la competitividad tecnológica europea, sino también la aparición de nuevos modelos de negocio basados en la confianza y el uso ético de los datos. De este modo, los espacios de datos no se limitan a ser un instrumento regulador, sino que representan una apuesta estratégica por un ecosistema digital europeo resiliente y autónomo.

3.1.2 Data Governance Act

La primera ley impulsada por la Estrategia Europea de Datos, que entró en vigor en septiembre de 2023, fue el Reglamento (UE) 2022/868, conocida como la Ley de Gobernanza de Datos (DGA). Su creación responde a un desafío fundamental que frenaba la economía digital europea: la parálisis de los datos. Inmensos volúmenes de información de gran valor, provenientes del sector público y del privado, permanecían sin ser compartidos debido a la incertidumbre jurídica y la ausencia de cauces fiables para su circulación.

La misión de la DGA es la de fomentar la compartición de datos a gran escala construyendo un entorno de confianza a través de varias medidas. Uno de sus ejes principales se enfoca en desbloquear el valor latente en el sector público, creando vías

seguras para reutilizar información sensible, como datos sanitarios en proyectos que beneficien al conjunto de la sociedad, mejorando la calidad de la sanidad y reduciendo sus costes.

A esta visión se suma el fomento del denominado altruismo de datos, facilitando que tanto personas físicas como jurídicas puedan ceder su información de forma voluntaria para fines de interés general.

Para que estos intercambios, tanto públicos como privados, se materialicen de forma segura, la ley diseña un rol crucial: el de los intermediarios de datos. Estas entidades son concebidas como organizadores neutrales y fiables, suponen un engranaje fundamental que garantiza la confianza dentro de los espacios de datos. Cabe destacar que la ley permite aplicar comisiones por la provisión de dicho servicio. Todas estas medidas convergen en un objetivo estratégico y transversal: facilitar que la información fluya sin fricciones a través de sectores y fronteras, permitiendo así que el dato correcto sea encontrado y utilizado para el fin correcto en cualquier lugar de la Unión Europea.

Para asegurar que este ecosistema funcione de manera coherente y soberana, la DGA introduce dos dimensiones adicionales clave. Por un lado, establece una estructura de gobernanza a nivel europeo a través del Comité Europeo de Innovación en materia de Datos (EDIB). Este comité de expertos se encarga de armonizar las prácticas entre los Estados miembros, fomentar la interoperabilidad y asesorar a la Comisión para una aplicación consistente de la ley. Por otro lado, la DGA refuerza la soberanía digital de la Unión Europea al incluir salvaguardias específicas para las transferencias internacionales de datos no personales, protegiéndolos frente a solicitudes de acceso indebidas por parte de autoridades de terceros países.

3.1.2.1 Reutilización de Datos Públicos

El Capítulo II de la DGA se diseña un mecanismo sofisticado para la reutilización segura y controlada de los datos. Se trata de un delicado ejercicio de equilibrio: facilitar el acceso para fines de interés general sin comprometer la protección de la información. Para lograrlo, articula una serie de principios rectores que deben seguir los organismos públicos que decidan permitir la reutilización:

- **Neutralidad y equidad de mercado:** Se prohíbe de forma general la concesión de derechos exclusivos sobre la reutilización de datos a una sola entidad. Esta medida es clave para prevenir la creación de monopolios de información y garantizar que el acceso al conocimiento público siga siendo público. Las condiciones impuestas a los reutilizadores deben ser siempre transparentes, proporcionadas y no discriminatorias.
- **Procesos claros y centralizados:** Para simplificar la interacción, cada Estado miembro debe designar puntos de información únicos que funcionen como ventanilla para todas las solicitudes. Esto profesionaliza y centraliza la gestión, ofreciendo un canal claro para los investigadores y las empresas.
- **Seguridad:** La piedra angular del sistema es la seguridad. La ley exige que el tratamiento de los datos para su reutilización se realice dentro de un entorno de procesamiento seguro controlado por el propio organismo público. Solo se permitirá la transmisión de resultados que no pongan en riesgo la información confidencial, por ejemplo, mediante técnicas de anonimización o agregación. En la práctica, el dato bruto sensible nunca debe abandonar el control de la entidad pública.

Este enfoque crea un círculo de confianza: las administraciones disponen de un protocolo seguro para gestionar las solicitudes, y los reutilizadores obtienen una vía legal predecible para acceder a información de alto valor.

Este marco de reutilización se aplica únicamente a los datos en poder de los organismos del sector público que estén protegidos por motivos como:

- **Confidencialidad comercial,** lo que incluye secretos comerciales, profesionales o empresariales.
- **Confidencialidad estadística.**
- **Protección de los derechos de propiedad intelectual de terceros.**
- **Protección de datos personales,** en la medida en que estos queden fuera del ámbito de la Directiva de Datos Abiertos.

Dentro del reglamento se establecen ciertas excepciones, quedando excluidos de este ámbito los datos en poder de empresas públicas, los organismos públicos de radiodifusión, los centros culturales y de enseñanza, y los datos protegidos por motivos de seguridad pública, defensa o seguridad nacional.

3.1.2.2 Servicios de Intermediación de Datos

Para asegurar la neutralidad de los intermediarios de datos en el artículo 12 se establecen varias condiciones para las prestaciones de servicio. El pilar central de esta neutralidad reside en la neutralización del conflicto de interés inherente a su función: prohibiendo de forma taxativa que el intermediario pueda explotar en beneficio propio los datos que simplemente transitan por su plataforma. Su función queda así delimitada a la de ser un mero facilitador del flujo de información.

Como respaldo a estos principios, el reglamento impone al proveedor la obligación de operar a través de una entidad jurídica propia, separada de otras unidades de negocio con las que pudieran surgir conflictos de interés, consolidando así su imparcialidad operativa.

A estos pilares de neutralidad se suma un mandato explícito de equidad y transparencia en la relación con el mercado donde se obliga a que el procedimiento de acceso, las condiciones y los precios sean equitativos, transparentes y no discriminatorios para todos los actores. Esto prohíbe en la práctica la existencia de acuerdos opacos, asegurando que las reglas del juego sean las mismas para todos los participantes.

Más allá de la conducta de un intermediario individual, el reglamento muestra una clara visión de futuro al exigir la creación de un ecosistema de datos abierto y no de silos cerrados. Para ello, impone la obligación de adoptar medidas para garantizar la interoperabilidad con otros servicios de intermediación. Esto es fundamental para prevenir que los intermediarios no se conviertan en los "gatekeepers" del mañana, asegurando que un usuario pueda moverse libremente entre servicios y que los espacios de datos de distintos sectores puedan comunicarse entre sí.

Para completar este marco de confianza, la regulación establece garantías concretas ante escenarios adversos o prácticas abusivas. Por un lado, se obliga al intermediario a

asegurar la continuidad razonable del servicio y asegurar el acceso a los datos en el caso que incluyera almacenamiento de datos incluso en caso de insolvencia. Esto protege al usuario frente a la desaparición del proveedor. Por otro lado, introduce una regla clásica de competencia justa que prohíbe condicionar la prestación del servicio a la contratación de otros productos, impidiendo así las ventas atadas (bundling) y protegiendo la libertad de elección del cliente.

3.1.2.3 Altruismo de datos

En paralelo al modelo comercial de intermediación, el Capítulo IV de la DGA diseña un canal seguro y fiable para el altruismo de datos. Reconoce que tanto individuos como empresas pueden estar dispuestos a donar datos de forma voluntaria si confían en que se usarán para un bien común. El objetivo es fomentar la cesión de datos para fines de interés general, como la investigación científica o la mejora de los servicios públicos.

La figura central de este modelo es la organización de gestión de datos con fines altruistas reconocida en la Unión. Para obtener este sello oficial, que se inscribe en un registro público europeo, la entidad debe cumplir requisitos estrictos, el más importante es su carácter no lucrativo y su independencia de cualquier entidad con fines comerciales. Su única finalidad debe ser la de promover el interés general.

Para facilitar este proceso, la DGA prevé la creación de un Formulario Europeo de Consentimiento, una herramienta modular y uniforme para toda la Unión que simplificará el acto de donar datos. Permitirá a los donantes otorgar un consentimiento granular y, de igual importancia, retirarlo de manera sencilla.

La ley detalla quiénes pueden ser estos donantes altruistas, distinguiendo entre dos categorías. Por un lado, los "interesados", que son las personas físicas que ceden sus datos personales mediante su consentimiento. Por otro, los "titulares de datos", que son las personas jurídicas como empresas u organizaciones, que pueden ceder tanto datos no personales de su propiedad como conjuntos de datos personales que obren en su poder, para lo cual otorgan su permiso.

En definitiva, mientras que los servicios de intermediación crean un mercado de datos neutral y competitivo, el marco de altruismo fomenta una economía de datos basada en

la solidaridad. Ambos mecanismos, con sus rigurosas salvaguardas, son complementarios y esenciales en la estrategia europea.

3.1.3 Data Act

Si el Reglamento de Gobernanza de Datos sentó las bases de la confianza para compartir datos, la Ley de Datos se ocupa de la fuente misma de esa información, estableciendo quién tiene derecho a acceder a ella y en qué condiciones. Considerada el segundo pilar de la Estrategia Europea, esta normativa interviene directamente sobre las reglas de acceso y propiedad para desbloquear el valor contenido en el universo de los productos conectados (IoT).

El principio que articula la ley es transformador: el valor generado por un dispositivo debe beneficiar, en primer lugar, a su usuario. Esta idea busca corregir la práctica habitual por la que los fabricantes actúan como únicos poseedores de los datos de sus productos. Al forzarles a facilitar el acceso, la ley posibilita un ecosistema de innovación mucho más abierto. La normativa entró en vigor a principios de 2024, aunque no será de plena aplicación hasta septiembre de 2025 para permitir la adaptación del mercado a este nuevo paradigma.

3.1.3.1 El Derecho de Acceso y Compartición

El núcleo de la Ley de Datos se materializa en un nuevo conjunto de derechos para los usuarios de productos conectados. En primer lugar, consagra el derecho del usuario a acceder a la totalidad de los datos que genera, de forma gratuita y sencilla. Pero el poder real reside en el segundo derecho: la capacidad de exigir al fabricante ("titular de los datos") que ponga esta información a disposición de un tercero elegido por el usuario, sin demoras indebidas y, cuando sea viable, de forma continua y en tiempo real.

Este mecanismo es el que habilita la competencia en los servicios tales como la posventa y los servicios de reparación. Es importante destacar que la ley equilibra este derecho con la necesidad de proteger los secretos comerciales del fabricante. El tercero que recibe los datos no puede utilizarlos para desarrollar un producto que compita directamente con el del fabricante, asegurando un marco de compartición justo.

3.1.3.2 Equilibrando el Poder de Negociación: Cláusulas Abusivas y Datos B2B

Para atajar el desequilibrio de poder en la negociación de contratos de datos entre empresas (B2B), la Ley de Datos articula una defensa para las pymes en dos niveles. Primeramente, existen cláusulas consideradas tan perjudiciales que la ley las declara nulas de forma incondicional.

Junto a estas, la normativa establece una segunda categoría para cláusulas que, si bien no son automáticamente nulas, sí levantan una presunción de abuso. Esto significa que la responsabilidad probatoria recae sobre la parte que impuso la condición. Es ella quien debe demostrar activamente que sus términos son equitativos, y no la pyme la que debe probar la injusticia. Este doble enfoque no solo elimina los abusos más flagrantes, sino que también fomenta una cultura de mayor equidad en la redacción de los futuros acuerdos de datos.

3.1.3.3 Facilitando la Portabilidad en la Nube y la Interoperabilidad

Otro de los grandes objetivos de la Ley de Datos es dismantelar las barreras que impiden la competencia efectiva en el sector de los servicios en la nube, atacando directamente el conocido como efecto de dependencia (vendor lock-in). En la práctica, muchos clientes, especialmente pymes, se ven atrapados con un único proveedor (como Amazon Web Services, Microsoft Azure o Google Cloud) no por la calidad del servicio, sino por las enormes dificultades técnicas, contractuales y, sobre todo, económicas que implica migrar sus datos a otro competidor. El obstáculo más significativo son los elevados costes de transferencia de datos (egress fees), tarifas que los proveedores cobran a los clientes por sacar sus propios datos de la plataforma.

En el capítulo IV la ley de datos confronta este problema de forma progresiva imponiendo la supresión gradual de las tarifas de abandono. A partir de la aplicación de la ley en septiembre de 2025 los proveedores deberán limitarse a cobrar estrictamente los costes reales que les genere el proceso de migración. Tras otro periodo de tres años estas tarifas por abandono quedarán completamente prohibidas y pasará a ser un servicio gratuito.

Además de eliminar las barreras económicas la ley aborda aspectos técnicos y contractuales. Por ejemplo, obliga a los proveedores a ser transparentes en los contratos conforme a los procedimientos necesarios para el cambio de proveedor y los plazos máximos para la portabilidad.

La visión de la Ley de Datos va más allá de un simple cambio de proveedor; apunta hacia un futuro multinube, donde las empresas ya no estén forzadas a apostar todo a un solo proveedor. La idea es que una compañía pueda, por ejemplo, usar el servicio de bases de datos de un proveedor y la potencia de cálculo para inteligencia artificial de otro, combinando las herramientas más potentes y rentables de cada uno. Para que esto sea posible, la ley impulsa la adopción de estándares técnicos abiertos al forzar a los proveedores a ser "interoperables" es decir, a que sus sistemas puedan comunicarse entre sí, se rompen las paredes de los ecosistemas cerrados y se fomenta un mercado más competitivo.

3.1.3.4. Acceso a Datos para Fines Públicos y Soberanía Digital(B2G)

Finalmente, la ley regula dos aspectos cruciales relacionados con el sector público. Por un lado, establece un mecanismo para que, en situaciones de necesidad excepcional de interés público (como emergencias sanitarias o catástrofes naturales), las administraciones puedan solicitar el acceso a datos en manos del sector privado. Este acceso no es un cheque en blanco: está estrictamente limitado a estas situaciones de emergencia, debe ser proporcionado y se compensará al titular de los datos.

Por otro lado, refuerza la soberanía digital de la UE al introducir salvaguardias contra las solicitudes de acceso a datos no personales por parte de gobiernos de terceros países. Los proveedores de servicios deben tomar todas las medidas razonables para impedir transferencias que sean contrarias al Derecho de la Unión, a menos que exista un tratado internacional que las regule.

3.1.4 Entorno tecnológico de los espacios de datos

La visión de los espacios de datos europeos, explicada en la sección anterior, requiere de un sólido soporte tecnológico para su materialización efectiva. Por ello, el presente

apartado se dedicará a desgranar el entorno tecnológico intrínseco de estos espacios analizando cómo los aspectos de seguridad, gobernanza de datos, la visión empresarial y el compliance se entrelazan para asegurar un correcto funcionamiento.

3.1.4.1 Seguridad

El artículo 32 del Reglamento General de Protección de Datos (Reglamento (UE) 2016/679) establece que toda entidad que trate datos personales debe adoptar medidas técnicas y organizativas adecuadas para garantizar un nivel de seguridad apropiado al riesgo. Estas medidas deben asegurar, entre otros aspectos, la confidencialidad, la integridad y la disponibilidad de los datos, reconocidos internacionalmente como los tres principios esenciales de la seguridad de la información (NIST, 2020).

La confidencialidad implica que los datos solo sean accesibles por personas o sistemas autorizados, protegiendo su contenido frente a accesos no deseados. La integridad garantiza que la información no se altere de manera no autorizada, manteniendo su exactitud y fiabilidad a lo largo del ciclo de vida. Finalmente, la disponibilidad asegura que los datos estén accesibles cuando sean necesarios, sin interrupciones indebidas que comprometan su uso legítimo.

En el contexto de los espacios de datos, el cumplimiento de estos principios requiere la aplicación de técnicas de protección robustas, como el cifrado de los datos tanto en tránsito como en reposo, la autenticación sólida de los agentes que acceden a los sistemas, el uso de controles de acceso estrictos, y la seudonimización o anonimización de los datos personales, especialmente en entornos abiertos o compartidos.

En el caso del aprendizaje federado, se requieren mecanismos de seguridad avanzados que permitan preservar la privacidad sin comprometer la capacidad de análisis. Entre ellos destacan la agregación segura, que permite combinar las actualizaciones locales de los modelos entrenados en cada nodo sin revelar el contenido individual de esas actualizaciones, protegiendo así los datos de cada participante frente al servidor central o posibles interceptores (Bonawitz et al., 2017); la privacidad diferencial, una técnica que introduce ruido matemáticamente calibrado en los datos o en las salidas del modelo para evitar que se puedan inferir datos personales a partir de los resultados, incluso tras

múltiples observaciones (Dwork, 2014); y la encriptación homomórfica, que permite realizar operaciones directamente sobre datos cifrados sin necesidad de descifrarlos, asegurando que la información sensible permanezca protegida en todo momento durante el procesamiento (Gentry, 2009). Estas técnicas refuerzan la protección de la información a lo largo del ciclo de vida del aprendizaje colaborativo, fortaleciendo la confianza en los ecosistemas federados y facilitando el cumplimiento normativo europeo. Autores como Manzoor et al. (2023) han documentado en su revisión sistemática cómo estas estrategias se han aplicado efectivamente en entornos de aprendizaje federado, consolidando su relevancia práctica en el diseño de arquitecturas seguras y escalables.

3.1.4.2 Gobernanza de datos

La gobernanza de datos se refiere al conjunto de políticas, procesos, normas y roles establecidos para garantizar una gestión ética, segura y eficaz de la información dentro de una organización o ecosistema digital. No se limita únicamente a regular el acceso a los datos, sino que abarca la supervisión integral de su ciclo de vida, asegurando su calidad, legalidad, trazabilidad y uso responsable (Otto, 2011).

En los espacios de datos federados, la gobernanza cobra una importancia aún mayor debido a la naturaleza descentralizada de estos entornos. A diferencia de los modelos centralizados, donde el control de los datos recae en una única entidad, en los sistemas federados es necesario coordinar normas y responsabilidades entre múltiples actores independientes. Esto requiere mecanismos que garanticen la interoperabilidad y el cumplimiento entre las partes, así como una distribución clara de responsabilidades. Iniciativas como la International Data Spaces Association (IDSA) comenzaron ya en 2019 a desarrollar modelos de referencia orientados al intercambio seguro y soberano de datos entre organizaciones. Aunque en ese momento aún no se utilizaba el término “espacios de datos federados”, los principios técnicos y normativos del modelo IDS sentaron las bases para su posterior desarrollo, incluyendo contratos de uso de datos, trazabilidad y normas comunes de interoperabilidad (IDSA, 2019). Diversas iniciativas europeas han trabajado desde entonces en la formalización de estos marcos. Un ejemplo destacado es GAIA-X, que en su versión más reciente del Architecture Document

plantea una arquitectura técnica y organizativa federada, compuesta por nodos interconectados gestionados por diferentes entidades. GAIA-X establece roles diferenciados como proveedores, consumidores y federadores de servicios, define normas de intercambio y control, e incorpora herramientas clave para la verificación de identidades, la certificación de servicios y la supervisión continua del ecosistema (Gaia-X, 2024). Este enfoque busca asegurar que la autonomía de los participantes no comprometa la confianza ni la interoperabilidad general del sistema.

Más allá de los aspectos técnicos, la gobernanza de datos también debe abordar dimensiones éticas y sociales. El uso creciente de tecnologías como el aprendizaje federado plantea desafíos específicos relacionados con la equidad, la representatividad de los datos distribuidos y la validación de modelos en entornos descentralizados. Diversos estudios han señalado que la heterogeneidad entre participantes y la ausencia de acceso centralizado a los datos pueden generar sesgos difíciles de detectar o corregir. Por ello, se recomienda implementar mecanismos de evaluación periódica, auditorías descentralizadas y estrategias que garanticen un comportamiento justo del modelo frente a la diversidad de datos y contextos entre los distintos clientes participantes (Kairouz et al., 2021).

3.1.4.3 Visión Empresarial

Los espacios de datos y el aprendizaje federado no solo representan avances técnicos o regulatorios, sino que también habilitan nuevas oportunidades para la transformación y el crecimiento empresarial. En una economía cada vez más orientada a los datos, estas tecnologías permiten a las organizaciones generar valor sin comprometer la privacidad ni la soberanía de la información, cumpliendo con los principios de una economía digital ética y sostenible (Zillner et al., 2021).

Entre las principales oportunidades de negocio destaca la posibilidad de desarrollar productos y servicios basados en análisis avanzados a partir de datos distribuidos. El aprendizaje federado permite entrenar modelos sin necesidad de centralizar los datos, facilitando así la cooperación entre entidades que operan bajo estrictas restricciones legales o comerciales (Yang et al., 2019). Esto habilita nuevas formas de colaboración

entre empresas, incluso competidoras mediante entornos seguros, lo que se traduce en un incremento del valor colectivo generado por los datos compartidos.

Algunos casos de uso concretos ilustran este potencial. Por ejemplo, en el sector logístico minorista, es posible mejorar la predicción de la demanda combinando fuentes de datos de distintos actores sin vulnerar la privacidad de los clientes (Li et al., 2021). En el ámbito sanitario, el aprendizaje federado permite analizar datos clínicos estructurados sin compartir información sensible, favoreciendo la investigación colaborativa (Xu et al., 2021). En entornos industriales, esta tecnología se aplica a la optimización de procesos, como el mantenimiento predictivo o el ajuste dinámico de la producción, a través del aprendizaje colaborativo entre plantas o empresas interconectadas (Lu et al., 2020).

3.1.4.4 Compliance y Normativa

El cumplimiento normativo o compliance en los espacios de datos y entornos de aprendizaje federado va más allá de la simple adhesión a marcos legales como el GDPR. Supone la creación de estructuras y procedimientos internos que aseguren de forma continua que toda la operativa asociada al ciclo de vida de los datos cumple con las normativas aplicables, estándares sectoriales y expectativas éticas de los stakeholders. Se trata de un enfoque proactivo y preventivo que integra el cumplimiento en el diseño mismo de los sistemas, lo que se conoce como compliance by design. (Sellami et al., 2023)

En este contexto, uno de los retos clave es la verificabilidad práctica del cumplimiento. Los espacios de datos deben estar acompañados de mecanismos técnicos y organizativos que permitan demostrar, ante terceros y autoridades reguladoras, que las operaciones respetan las restricciones legales sobre acceso, tratamiento, almacenamiento y transferencia de datos. Para ello, son necesarias herramientas de trazabilidad avanzada, registros de actividad (logging), pruebas de consentimiento explícito, e incluso soluciones tecnológicas como los contratos inteligentes que ejecutan automáticamente restricciones de uso previamente pactadas (Finck & Pallas, 2020).

Además, el cumplimiento debe extenderse a las fases de auditoría y evaluación continua. Esto implica integrar procedimientos de revisión periódica, auditorías internas o externas, y evaluación de impacto en protección de datos (DPIA), especialmente en sectores sensibles como la salud o las finanzas. Este tipo de auditoría no solo busca identificar incumplimientos, sino también mitigar riesgos emergentes, como la reidentificación no intencionada de usuarios a través de inferencias algorítmicas (Veale & Borgesius, 2021).

3.2 Estrategia de IA de la Unión europea

Hasta el momento se ha tratado cómo la Unión Europea ha llevado a cabo sobre todo medidas legislativas, pero se la ha tratado como un agente pasivo. En este apartado se tratará la principal iniciativa ya centrada en la práctica promulgada por la Unión Europea. En este caso, la UE pretende establecer una robusta infraestructura de IA a través de la iniciativa de "Fábricas de IA", con el fin de consolidar su competitividad tecnológica en el ámbito de la inteligencia artificial. Estas instalaciones son ecosistemas dinámicos que fomentan la innovación y la colaboración, reuniendo poder computacional, datos y talento para desarrollar modelos y aplicaciones de IA de vanguardia. Las Fábricas de IA promueven la cooperación en toda Europa, conectando centros de supercomputación, universidades, pymes, la industria y actores financieros, sirviendo como centros impulsores del avance de la IA en sectores clave como la salud, manufactura, clima, finanzas y espacio. A continuación, se muestran la organización actual de las factorías de IA.




Figura 1. Mapa AI Factories. (EuroHPC JU, 2025)

En la Figura 1 se representa en el mapa europeo las 13 factorías de IA confirmadas a lo largo de los 17 estados miembros y 2 EuroHPC estados participantes. Todos estos participantes estarán interconectados y se establecerá un marco colaborativo para crear una red común.

Los colores en el mapa representan lo siguiente:

- **Azul oscuro:** Países que albergan una Fábrica de IA ("AIF Hosting Countries").
- **Amarillo:** Países socios de una Fábrica de IA ("AIF Partner Countries").
- **Azul claro:** Estados participantes de EuroHPC restantes ("Remaining EuroHPC Participating States"), que no son anfitriones ni socios directos de una Fábrica de IA en este mapa, pero forman parte de la red de computación de alto rendimiento.

3.2.1. Gigafábricas

Dentro del marco de las Fábricas de IA, las Gigafábricas de IA representan su evolución a gran escala cuadruplicando la capacidad de computación de las fábricas de IA. Las

Gigafábricas de IA son grandes instalaciones dedicadas al desarrollo y entrenamiento de modelos de IA que podrían llevar al siguiente nivel conteniendo billones de parámetros. Para lograrlo, estas Gigafábricas deben reunir una enorme potencia de cómputo usando alrededor de 100.000 procesadores avanzados para IA. Además, harán un fuerte énfasis en la capacidad energética, las cadenas de suministro fiables, las redes avanzadas, la eficiencia energética y la automatización impulsada por la IA.

Estas infraestructuras clave se diseñarán para operar de manera federada con la red de Fábricas de IA de EuroHPC, la Empresa Común Europea de Computación de Alto Rendimiento que gestiona los superordenadores en Europa. También se integrarán con la nube soberana europea, facilitando su interconexión y estableciendo un marco de colaboración efectivo para una red común. Dada la considerable inversión necesaria para proyectos de esta magnitud, la Unión Europea enfatiza la necesidad de establecer sólidas asociaciones público-privadas.

3.2.2 Implementación actual

El proceso para la implementación de las factorías ya ha comenzado: el 9 de abril de 2025, la Empresa Común EuroHPC (EuroHPC JU) lanzó una Convocatoria para Manifestaciones de Interés (Call for Expression of Interest - CfEoI). Esta fase exploratoria no vinculante busca recopilar ideas de proyectos, enfoques de asociación y evaluar la viabilidad técnica y financiera. Actualmente, la iniciativa cuenta con un sólido respaldo del Consejo de Administración de EuroHPC, y los Estados miembros de la UE están mostrando un gran interés. El sector privado también ha respondido positivamente, destacando un fuerte compromiso de empresas tecnológicas, centros de datos, proveedores de energía y fondos de inversión europeos e internacionales. Como resultado de la convocatoria se alcanzaron unas 76 propuestas detalladas, provenientes de 16 estados miembros y de 60 localizaciones distintas.

3.2.3 Objetivo Estratégico y Escala de Despliegue de la UE

La Comisión Europea ha identificado el establecimiento de las Fábricas de IA como una prioridad estratégica, según lo anunciado en el Paquete de Innovación en IA de 2024. Este compromiso se ve reforzado por el Plan de Acción del Continente IA, que impulsa

significativamente la inversión de la UE en estas Fábricas. El objetivo principal es impulsar la autonomía tecnológica y asegurar una posición de vanguardia de Europa en el campo de la IA, fomentando un ecosistema robusto.

Para lograr estos objetivos, la escala de despliegue para 2025-2026, se espera que al menos 15 Fábricas de IA y varias Antenas (asociadas a superordenadores optimizados para IA en Fábricas de IA existentes) estén operativas, creando un ecosistema de IA paneuropeo. Esto también promoverá el crecimiento al priorizar el acceso para startups y pymes de IA. En este contexto, se adquirirán y desplegarán al menos 9 nuevos superordenadores optimizados para IA en toda la UE, lo que más que triplicará la capacidad actual de computación de IA de EuroHPC. Además, el InvestAI Facility, un fondo europeo diseñado para movilizar inversiones de IA a gran escala, está previsto que movilizará un nuevo fondo europeo de 20.000 millones de euros para la creación de hasta 5 Gigafábricas de IA, demostrando la magnitud del compromiso de la Unión Europea con esta infraestructura clave. Destacar que, en el marco global de InvestAI, la inversión total prevista asciende a 200.000 millones de euros para impulsar el desarrollo y aplicación de la IA en Europa.

3.2.4 Modelo de Financiación: Las Alianzas Público-Privadas

Un despliegue de esta envergadura exige un músculo financiero que ni el sector público ni el privado pueden desarrollar en solitario. La respuesta de la UE es el AI Global Facility (AIGF), un modelo de colaboración diseñado para la creación de este nuevo ecosistema de IA.

El enfoque planteado se basa en las alianzas público-privadas (PPP) con un pacto bien definido: las instituciones públicas impulsan el arranque con hasta el 35 % del coste de construcción (CAPEX). A cambio, la iniciativa privada asume el liderazgo asegurando el 65 % restante y, fundamentalmente, todos los costes operativos (OPEX).

Este reparto de cargas y riesgos está diseñado para ser flexible y atraer a toda la cadena de valor, desde la industria hasta los grandes fondos.

3.3 Aproximación distribuida de la Inteligencia artificial

Habiendo detallado la Estrategia Europea de Datos y su entorno tecnológico, con énfasis en la seguridad, la gobernanza y las oportunidades empresariales, es fundamental abordar la maximización del valor de estos datos distribuidos. La aproximación descentralizada que caracteriza a los espacios de datos no solo promueve la soberanía y la privacidad, sino que demanda, inherentemente, una madurez creciente de enfoques tecnológicos distribuidos que aporten valor significativo.

En este contexto, la Inteligencia Artificial (IA) juega un papel crucial. Dentro del ámbito de la IA, la respuesta idónea a esta necesidad de descentralización y protección de datos es la aproximación distribuida, siendo el entrenamiento federado su manifestación más relevante. La siguiente sección ahondará en los fundamentos del machine learning y explicará cómo el entrenamiento federado se posiciona como una metodología esencial para extraer conocimiento de los datos sin comprometer los principios de privacidad y control ya establecidos en los espacios de datos.

3.3.1 Fundamentos del aprendizaje automático

El aprendizaje automático es la rama de la informática que explora cómo los algoritmos pueden aprender directamente de los datos. La meta es que mejoren su desempeño en tareas específicas, sin que se les diga explícitamente cómo hacer cada cosa. Como lo definió Mitchell en 1997, si un programa de ordenador "aprende de la experiencia E con respecto a una clase de tareas T y una medida de rendimiento P, su ejecución en las tareas de T, medida por P, mejora con la experiencia E." Esta perspectiva es clave, pues destaca el proceso adaptativo inherente al aprendizaje.

El termino Machine Learning se acuñó a finales de los años 50 por Arthur Samuel que desarrolló programas que jugaban a las damas, demostrando como una máquina podía mejorar su rendimiento a través de la experiencia. En esos mismos años surgieron los primeros modelos de redes neuronales, como el caso del Perceptrón de Frank Rosenblatt (1957) que fue un primer acercamiento que pretendía imitar el funcionamiento cerebral aprendiendo patrones sencillos.

Tradicionalmente distinguimos tres grandes tipos de aprendizaje automático:

Aprendizaje Supervisado: es un tipo de machine learning que aprende la relación entre la entrada y la salida. Las entradas se conocen como características o "variables X" y la salida suele denominarse objetivo o "variable Y". El tipo de datos que contiene tanto las características como el objetivo son los datos etiquetados. El aprendizaje supervisado utiliza algoritmos que aprenden la relación de las características y el objetivo a partir del conjunto de datos.

Existen dos tipos de aprendizaje supervisado:

Regresión: La regresión es una categoría de técnicas en el aprendizaje automático que permite predecir un valor de salida continuo o numérico. Para lograrlo, estos métodos aprenden la relación entre las variables de entrada y la variable de salida a partir de datos históricos. Y emplean diversas estrategias para ajustar los parámetros del modelo, como los Mínimos Cuadrados (Least Squares) y el Descenso de Gradiente (Gradient Descent).

Clasificación: es una tipología de algoritmos de aprendizaje automático cuyo objetivo es predecir una categoría a partir de una entrada de datos determinada. Para ello, los modelos aprenden patrones en los datos etiquetados para determinar a qué grupo pertenece cada nueva entrada.

Aprendizaje No Supervisado: es un tipo de aprendizaje automático que no depende de datos etiquetados. Su objetivo principal es descubrir patrones ocultos, estructuras intrínsecas o relaciones significativas dentro de los datos por sí mismo, sin una guía previa sobre cuáles deberían ser los resultados. Este enfoque es particularmente útil en escenarios donde el etiquetado manual de datos es inviable o demasiado costoso. Sus aplicaciones incluyen la segmentación de clientes (para agrupar a usuarios con comportamientos similares sin saber de antemano cuántos grupos existen), la detección de anomalías o valores atípicos, y la creación de motores de recomendación (donde se descubren asociaciones entre ítems o preferencias de usuarios para sugerir contenido relevante).

El aprendizaje no supervisado puede dividirse en tres tareas principales:

Agrupación: consisten en agrupar datos no etiquetados basándose en sus similitudes y diferencias. Cuando dos instancias aparecen en grupos diferentes, podemos deducir que tienen propiedades distintas. Este tipo de aprendizaje es más conocido como Clustering.

Reglas de asociación: estas reglas sirven para encontrar patrones de co-ocurrencia entre elementos o eventos. Permitiendo descubrir combinaciones de artículos que aparecen frecuentemente juntos.

Reducción de la dimensionalidad: El método más conocido es el ACP (análisis de los componentes principales). Estas tipologías de algoritmo tratan de transformar los espacios de datos de alta dimensión en espacios de datos de baja dimensión sin comprometer la información única de los componentes. Así se elimina el ruido y la información redundante.

Aprendizaje por Refuerzo: es una técnica de machine learning que entrena al software para que tome decisiones y logre los mejores resultados. Imita el proceso de aprendizaje por ensayo y error que los humanos utilizan para lograr sus objetivos. Las acciones de software que trabajan para alcanzar su objetivo se refuerzan, mientras que las que se apartan del objetivo se ignoran. Los algoritmos de RL utilizan un paradigma de recompensa y castigo al procesar los datos. Aprenden de los comentarios de cada acción y descubren por sí mismos las mejores rutas de procesamiento para lograr los resultados finales. Los algoritmos también son capaces de funcionar con gratificación aplazada. La mejor estrategia general puede requerir sacrificios a corto plazo, por lo que el mejor enfoque descubierto puede incluir algunos castigos o dar marcha atrás en el camino.

En el siguiente apartado se explicarán los algoritmos principales que se emplearon en el presente trabajo.

3.3.2 Algoritmos:

Multi-layer Perceptron (MLP)

El Perceptrón Multicapa (MLP) es una clase fundamental de red neuronal diseñada para abordar problemas de clasificación y regresión. Su importancia radica en su capacidad

para modelar relaciones no lineales complejas entre entradas y salidas, superando las limitaciones de los perceptrones simples gracias a la introducción de capas ocultas. Si bien sus raíces se extienden a los primeros trabajos sobre redes neuronales, el algoritmo clave que permitió su entrenamiento efectivo, la retropropagación, fue descrito por Paul Werbos en su tesis doctoral de 1974.

Un perceptron multicapa es esencialmente un conjunto de perceptrones interconectados y organizados en capas. Típicamente consta de al menos tres capas:

Capa de entrada: Recibe los datos iniciales. El número de neuronas en esta capa corresponde a la cantidad de características en el conjunto de datos.

Capas ocultas: Una o más capas intermedias entre la entrada y la salida. Cada neurona en estas capas procesa la información de la capa anterior y la pasa a la siguiente. La capacidad del MLP para aprender patrones complejos se debe en gran medida a la presencia y el número de estas capas.

Capa de salida: Produce el resultado final del modelo (una predicción numérica para regresión o una probabilidad para clasificación). El número de neuronas aquí depende de la naturaleza del problema (por ejemplo, una para regresión, una para clasificación binaria o una por clase para clasificación multiclase).

Cada conexión entre neuronas tiene un peso asociado y cada neurona excepto las de la capa de entrada tiene un sesgo (bias). La señal que atraviesa una neurona se transforma mediante una función de activación (como la sigmoide, ReLU o tanh), que introduce la no linealidad necesaria para aprender patrones complejos.

El entrenamiento de un MLP se realiza utilizando el algoritmo de retropropagación (backpropagation). Este proceso iterativo implica:

Propagación hacia adelante (forward pass): Los datos de entrada atraviesan la red, activando cada neurona y propagando la señal hasta la capa de salida para generar una predicción.

Cálculo del error: La predicción de la red se compara con el valor real (etiqueta) utilizando una función de pérdida (o coste), que cuantifica el error del modelo.

Retropropagación del error (backward pass): El error se propaga hacia atrás a través de la red, desde la capa de salida hasta las capas de entrada. Durante esta fase, se calcula el gradiente de la función de pérdida con respecto a cada peso y sesgo de la red.

Actualización de pesos y sesgos: Utilizando un optimizador comúnmente el descenso de gradiente, los pesos y sesgos de la red se ajustan en la dirección que minimiza la función de pérdida, reduciendo el error.

Support Vector Machine (SVM)

Support Vector Machine (SVM) es una técnica de aprendizaje supervisado desarrollada por Vapnik (1995) para resolver problemas de clasificación y regresión. Su popularidad se debe a su capacidad para construir clasificadores robustos incluso en espacios de alta dimensionalidad, gracias a su fundamento matemático sólido y su flexibilidad para manejar tanto problemas linealmente separables como no linealmente separables.

SVM es un clasificador discriminativo que intenta generar un hiperplano óptimo para separar los datos de las diferentes clases con el mayor margen posible. En el caso de un espacio bidimensional, este hiperplano divide el plano en dos regiones, cada una correspondiente a una clase distinta. El objetivo es encontrar el hiperplano que maximice la distancia entre los puntos más cercanos de cada clase, conocidos como vectores de soporte y el propio hiperplano.

La ecuación general del hiperplano es:

$$x \cdot w + b = 0$$

donde w es un vector normal al hiperplano, b es el sesgo o bias, y $x \cdot w$ representa el producto punto entre los vectores de entrada y el vector normal.

Separación lineal

En el caso ideal los datos pueden separarse completamente por un hiperplano. Los puntos que se ubican justo en los bordes del margen son los llamados vectores de soporte y satisfacen la siguiente condición:

$$x_k \cdot w + b = \pm 1$$

Se busca entonces una solución óptima para que maximice el margen entre estos hiperplanos paralelos, garantizando una separación clara y eficiente entre clases.




Figura 3. Representación funcionalidad SVM. (James, G. et al., 2013)

Este caso es un ejemplo de separación perfecta donde se aprecia que corta en mitad de los puntos de soporte de ambas clases.

Soft margin

En la mayoría de los contextos reales los datos no son perfectamente separables. Para tratar con esta situación, se introducen variables de holgura que permiten al modelo aceptar ciertos errores de clasificación. Esta variante del algoritmo se conoce como SVM con margen suave (soft margin) y tiene como finalidad lograr un equilibrio entre dos objetivos: mantener un margen lo más amplio posible y reducir los errores de clasificación. Esta formulación lo hace especialmente adecuado para trabajar con datos parcialmente solapados.




Figura 4. Representación funcionalidad SVM. (James, G. et al., 2013)

La imagen muestra un clasificador SVM donde la línea continua representa el hiperplano y las discontinuas los márgenes. Las observaciones 2, 3, 4, 5, 6, 7 y 10 están correctamente clasificadas fuera del margen. Las observaciones 1 y 8 están dentro del margen, pero del lado correcto, por lo que también están bien clasificadas. En cambio, las observaciones 11 y 12 están en el lado incorrecto del hiperplano, lo que indica una clasificación errónea.

Separación no lineal con kernels

Cuando los datos no son linealmente separables ni siquiera usando soft margin, se recurre a una transformación del espacio de entrada en un espacio de mayor dimensión donde sí sea posible realizar una separación lineal. Esta transformación se realiza mediante el uso de funciones kernel, un procedimiento conocido como kernel trick (Aizerman et al., 1964).

Entre los kernels más comunes destacan:

- **Kernel lineal:** Se utiliza en problemas donde se espera que las clases puedan separarse linealmente o cuando se trabaja con datos dispersos o de alta dimensionalidad.

- **Kernel polinomial:** Permite modelar relaciones no lineales mediante polinomios de distintos grados. Es eficiente y conceptualmente simple, aunque puede volverse complejo con polinomios de alto grado.
- **Kernel RBF (Radial Basis Function):** Uno de los más utilizados en la práctica. Este kernel es especialmente útil cuando no se tiene conocimiento previo sobre la distribución de los datos, ya que puede adaptarse a una amplia variedad de formas de frontera de decisión.

Adaptación SVM para entrenamiento federado:

Tal como se explicó previamente, el entrenamiento federado moderno se apoya principalmente en variantes del algoritmo de descenso estocástico del gradiente (SGD). Esto implica que los modelos deben adaptarse a un esquema de optimización iterativa distribuida. En consecuencia, no es viable utilizar un SVM de forma tradicional, ya que este se entrena mediante técnicas de optimización convexa centralizada. Para resolver esta limitación, se optó por emplear un SGDClassifier al que se le incorporó una función de pérdida hinge, lo que lo convierte en un clasificador lineal equivalente a un SVM con margen suave (soft margin), pero entrenado de forma incremental.

Métricas de evaluación

Las métricas de evaluación son fundamentales para entender el rendimiento de un modelo de aprendizaje automático.

Matriz de confusión: En el caso de un problema de clasificación binaria, la matriz de confusión se compone de cuatro celdas distintas que proporcionan un panorama completo del rendimiento del modelo:

TP – Verdadero Positivo: La predicción positiva coincide con el valor real.

FP – Falso Positivo: ocurre cuando tu modelo predice un resultado positivo, pero en realidad, el valor es negativo.

TN – Verdadero Negativo: sucede cuando tu modelo predice correctamente un resultado negativo.

FN – Falso Negativo: Esto se produce cuando tu modelo predice un resultado negativo, pero en realidad, el valor es positivo.

A partir de la matriz de confusión, se derivan diversas métricas para analizar el rendimiento del modelo desde diferentes perspectivas:

Accuracy: se estima como el número de predicciones acertadas divididas entre el total de predicciones.

$$ACC = \frac{TP + TN}{TP + TN + FN + FP}$$

Recall: Se estima como el número de verdaderos positivos dividido entre el total de elementos positivos reales (es decir, la suma de los verdaderos positivos y los falsos negativos).

$$REC = \frac{TP}{TP + FN}$$

Precision: Se estima como el número de verdaderos positivos dividido entre el total de predicciones positivas (es decir, la suma de los verdaderos positivos y los falsos positivos).

$$PREC = \frac{TP}{TP + FP}$$

ROC-AUC: La Curva ROC es una representación gráfica que evalúa el rendimiento de un clasificador binario a través de todo el espectro de posibles umbrales de decisión. Esta curva se construye aplicando la Tasa de Verdaderos Positivos en el eje Y (TPR) y la Tasa de Falsos positivos en el eje X (1- (FPR)). Cada punto de la curva corresponde a un umbral de clasificación distinto. El umbral de decisión es el punto de corte establecido sobre las probabilidades de pertenencia a la clase positiva. Dado que el clasificador produce una puntuación de probabilidad continua, el umbral determina el

valor a partir del cual una instancia se asigna a la clase positiva, o en caso contrario negativa. Generalmente se aplica un umbral del 0.5 lo que significa que debe existir más de un 50% de probabilidades que pertenezca a la clase positiva para clasificarse como tal. El umbral puede modificarse si se quiere priorizar la detección de alguna de las clases.

EL AUC consolida la totalidad de la información contenida en la curva, y obtiene un valor el cual oscila entre 0 y 1. Este valor representa la probabilidad de que el modelo asigne una puntuación superior a una instancia positiva seleccionada aleatoriamente en comparación con una instancia negativa aleatoria. Por lo cual, mayor sea esa probabilidad mejor predictor será. Por este motivo el ROC-AUC es un indicador fiable para medir el rendimiento general.




Figura 5: Tres puntos etiquetados que representan umbrales. (Google, n.d.))

3.3.3 Centralizado y federado

El aprendizaje automático tradicional se basa en la centralización de datos provenientes de distintas fuentes en un único servidor, donde se entrena un modelo global. Este enfoque requiere la transferencia completa de los datos a un repositorio centralizado, lo cual puede resultar inadecuado en contextos donde la privacidad, la confidencialidad o la soberanía de los datos son prioritarias. Además, puede generar riesgos relacionados con la seguridad, la exposición de datos sensibles, el cumplimiento normativo o incluso la viabilidad técnica cuando el volumen de datos es demasiado elevado.

Frente a estas limitaciones, el aprendizaje federado (Federated Learning, FL) acuñado inicialmente por Google en 2016 surge como una alternativa descentralizada al paradigma clásico. Este nuevo enfoque permite entrenar modelos de aprendizaje automático de manera colaborativa, sin necesidad de trasladar los datos. En su lugar, cada cliente (nodo) entrena localmente un modelo a partir de sus propios datos y envía únicamente los parámetros actualizados del modelo (no los datos en sí) al servidor central, que se encarga de combinarlos para actualizar una versión global del modelo. Este modelo global actualizado se redistribuye a los clientes seleccionados, iniciando así una nueva ronda de entrenamiento.

Este proceso se repite durante múltiples rondas permitiendo que el modelo global aprenda progresivamente a partir del conocimiento distribuido de los distintos clientes. El aprendizaje federado ha demostrado ser especialmente útil en entornos con información sensible o altamente distribuidos, como aplicaciones móviles, dispositivos del internet de las cosas (IoT) y sistemas hospitalarios, donde los datos permanecen en su origen y no es viable o deseable transferirlos.

Además de sus ventajas en términos de preservación de la privacidad, el aprendizaje federado también permite reducir la sobrecarga de comunicación, disminuir el riesgo de ataques centralizados y fomentar la soberanía de los datos ya que cada participante conserva el control sobre su información. Sin embargo, esta arquitectura también introduce nuevos desafíos: la heterogeneidad de los datos entre clientes (por ejemplo, no-IID) y la necesidad de garantizar una coordinación eficiente del proceso de entrenamiento distribuido.

Si bien las técnicas específicas para combinar los modelos entrenados localmente en el server conocidos como algoritmos de agregación son fundamentales para el éxito del enfoque federado, estas serán abordadas con mayor profundidad en apartados posteriores.




Figura 6. Representación infraestructura federada. Fuente: elaboración propia.

En esta figura se representan las distintas etapas que conforman un proceso de entrenamiento federado:

Paso 1: El servidor central configura un modelo inicial, del mismo modo que se haría en un enfoque centralizado.

Paso 2: El modelo inicial se distribuye desde el servidor a los distintos nodos participantes (clientes).

Paso 3: Cada nodo entrena el modelo recibido localmente durante una o varias épocas, utilizando únicamente sus propios datos. Tal como se indica en la parte inferior de la figura, en esta fase los nodos ejecutan el modelo de forma autónoma, como si se tratara de entrenamientos centralizados independientes.

Paso 4: Una vez completado el entrenamiento local, cada nodo envía al servidor los pesos actualizados de su modelo. Este proceso ocurre de forma paralela entre los distintos clientes.

Paso 5: El servidor aplica un algoritmo de agregación que permite combinar los modelos locales en un único modelo global. Este ciclo se repite durante varias rondas hasta alcanzar la convergencia deseada. Al finalizar el proceso, se obtiene un modelo global que ha sido entrenado de forma colaborativa, sin necesidad de centralizar los datos.

3.4 Metodologías de entrenamiento federado

3.4.1 Metodología en función de la infraestructura

En el ámbito del entrenamiento federado, se distinguen principalmente dos tipos de enfoques según el contexto en el que se implemente: cross-device y cross-silo. Ambos comparten la característica de preservar la privacidad de los datos al evitar su centralización, pero difieren significativamente en cuanto a la naturaleza de los participantes y los desafíos técnicos asociados.

El enfoque cross-device implica la participación de un gran número de dispositivos personales heterogéneos, como teléfonos móviles o tablets, cada uno con pequeñas cantidades de datos locales. Este tipo de entrenamiento federado está caracterizado por una alta escala y una elevada heterogeneidad en términos de capacidad computacional, conectividad y estado del dispositivo. Las principales dificultades que presenta incluyen la intermitencia en la conexión, y la coordinación eficiente entre dispositivos con características muy dispares (Kairouz et al. 2021)

Para abordar estos desafíos, se han propuesto técnicas como la compresión de la comunicación, que reduce el tamaño de los modelos o gradientes transmitidos y la agregación asincrónica que permite integrar las actualizaciones de los clientes conforme se reciben, sin necesidad de esperar a todos los participantes. No obstante, estas técnicas pueden presentar limitaciones en términos de rendimiento y eficiencia. Para superar estos problemas, Chen et al. (2023) desarrollan la plataforma FS-Real, diseñada específicamente para gestionar de manera eficiente estas estrategias. Su propuesta permite eliminar las deficiencias de rendimiento asociadas a las técnicas anteriores, logrando reducir los tiempos de entrenamiento y mejorar significativamente la escalabilidad del sistema.

El enfoque cross-silo, por su parte, implica un número más reducido de clientes con infraestructura más estable, como pueden ser instituciones o empresas. Esta configuración resulta especialmente adecuada en contextos sectoriales (por ejemplo, salud, educación o turismo). En estos entornos, la relativa homogeneidad de los participantes facilita la aplicación de estrategias de coordinación más estructuradas,

como la agregación sincrónica, permitiendo una supervisión más rigurosa del proceso de entrenamiento. Estudios como Gorbett et al. (2023) demuestran que mediante la alineación iterativa de parámetros es posible mejorar significativamente la robustez y capacidad de generalización del modelo en entornos cross-silo, especialmente cuando los participantes provienen de dominios divergentes.

3.4.2 Metodología en función de los datos

El aprendizaje federado (FL) puede clasificarse en función de cómo se distribuyen las variables y las observaciones entre los participantes. Esta clasificación permite adaptar los métodos de entrenamiento a distintos contextos colaborativos.

Aprendizaje Federado Horizontal (HFL): los participantes disponen del mismo espacio de características, pero sus conjuntos de datos contienen diferentes muestras. Este enfoque es común en organizaciones que manejan datos estructurados de forma similar, como hospitales o bancos. Se han propuesto múltiples arquitecturas de entrenamiento y comunicación para optimizar la eficiencia en este contexto (Kairouz et al., 2021).

Aprendizaje Federado Vertical (VFL): los participantes poseen diferentes subconjuntos de características sobre las mismas entidades. Este escenario requiere técnicas de emparejamiento de datos y aprendizaje colaborativo más sofisticadas. Un enfoque destacado consiste en aprender representaciones embebidas compartidas que proyectan las características verticalmente dispersas en un espacio común, facilitando la colaboración sin comprometer la privacidad (Liu et al., 2020). Además, técnicas como el dropout estructural pueden aplicarse para reducir redundancia y mejorar la generalización del modelo. En esta línea, Hartmann et al. (2023) proponen el marco JoVe-FL (Joint-embedding Vertical Federated Learning), que transforma el problema vertical en uno horizontal mediante el aprendizaje de un espacio de embedding conjunto, lo que permite aprovechar técnicas ya consolidadas en el aprendizaje horizontal, mejorando así la eficiencia y reduciendo los costes de comunicación.

Aprendizaje Federado por Transferencia (FTL): esta modalidad se emplea cuando los clientes no comparten ni características ni muestras. Resulta útil en entornos altamente heterogéneos, como entre instituciones de salud y compañías aseguradoras. En estos

casos se aplican técnicas de transferencia de conocimiento, como la destilación de conocimiento (Zhang et al., 2022), que permiten establecer relaciones útiles entre dominios distintos sin necesidad de compartir directamente los datos.

3.4.3 Metodología en función del algoritmo de agregación

Para abordar los desafíos del aprendizaje federado, especialmente aquellos derivados de la heterogeneidad de los datos y la asincronía entre dispositivos, se han desarrollado diversas estrategias de agregación adaptativa. Métodos como FedAvg (McMahan et al., 2017), FedProx (Li et al., 2020), FedNova (Wang et al., 2020) o FedMA (Wang et al., 2020) ajustan la combinación de los modelos locales considerando aspectos como el tamaño y la calidad de los datos, la divergencia entre parámetros o la frecuencia de participación de los clientes, lo que permite mejorar la estabilidad y acelerar la convergencia del modelo global. El trabajo fundacional de McMahan et al. (2017) introdujo el concepto formal de entrenamiento federado junto con el algoritmo Federated Averaging (FedAvg), que demostró la viabilidad de entrenar modelos colaborativos con una eficiencia comunicativa razonable y un rendimiento comparable al aprendizaje centralizado, incluso en contextos donde los datos se encuentran distribuidos de forma no independiente e idénticamente distribuida (non-IID). En estos escenarios, cada cliente dispone de datos con características particulares y potencialmente sesgadas, lo que representa uno de los principales retos del aprendizaje federado. Por ejemplo, en una red de dispositivos móviles, algunos usuarios pueden tener datos relacionados únicamente con ciertas categorías o patrones de comportamiento, como aplicaciones específicas que utilizan con mayor frecuencia, o estilos particulares de escritura si se trata de predicción de texto. Otros usuarios, en cambio, pueden generar datos completamente distintos según su contexto o uso. Esta disparidad entre los datos locales de cada cliente puede dificultar el aprendizaje generalizado del modelo global, ya que no todos los clientes aportan la misma variedad de información.

A pesar de ello, el estudio demostró que ajustando parámetros como el número de épocas locales (E) o la proporción de clientes participantes en cada ronda (C), FedAvg puede alcanzar una precisión global elevada con una cantidad significativamente menor

de comunicación. Este hallazgo fue clave para el desarrollo posterior del campo y ha sido confirmado y ampliado en investigaciones más recientes (Li et al., 2020).

FedAvg puede entenderse como una extensión descentralizada del descenso estocástico del gradiente (SGD). Mientras que el SGD tradicional se aplica en entornos centralizados donde todos los datos se encuentran en un único servidor y se actualiza el modelo en función de batches aleatorios del conjunto completo, FedAvg adapta esta lógica a un contexto distribuido. Cada cliente realiza localmente varios pasos de SGD sobre sus propios datos, manteniéndolos en todo momento en su dispositivo. Posteriormente, los modelos actualizados localmente se envían al servidor, donde se agregan mediante una media ponderada que simula el efecto de una única actualización global, como si los datos hubieran estado centralizados.

Otras técnicas posteriores que intentaron mejorar el FedAvg, como FedProx, ampliaron esta idea incorporando un término de regularización, es decir, un ajuste extra que ayuda a evitar que los modelos de cada cliente diverjan demasiado del modelo global. Para ello, modifican la función de pérdida local, que es el cálculo que cada cliente hace para saber cuánto se equivoca su modelo y cómo corregirlo. Con este mecanismo se consigue que el entrenamiento sea más estable, especialmente cuando los datos de los clientes son muy diferentes entre sí.

Por su parte, FedNova propone una normalización explícita de las actualizaciones locales basada en el número total de pasos de optimización realizados por cada cliente, lo que permite corregir el sesgo que se introduce cuando los dispositivos participantes ejecutan diferentes cantidades de épocas de entrenamiento.

Esta estrategia resulta especialmente útil en entornos asincrónicos o con recursos heterogéneos, donde algunos clientes pueden completar más épocas o procesar más lotes de datos que otros, debido a diferencias en capacidad computacional, conectividad o disponibilidad.

A diferencia de FedAvg, que realiza un promedio ponderado por el tamaño del conjunto de datos de cada cliente presuponiendo que todos realizan una cantidad similar de entrenamiento, FedNova garantiza una agregación más equitativa ajustando también por

el esfuerzo de cómputo local. Esta normalización contribuye a reducir la deriva de optimización y a mejorar la estabilidad del modelo global en contextos no sincronizados o altamente variables.

Por otro lado, FedMA aplica una estrategia basada en el emparejamiento y alineamiento de neuronas entre modelos, lo que permite combinar representaciones locales de forma más coherente en redes profundas, siendo especialmente útil cuando las arquitecturas o las distribuciones de datos son altamente dispares. (Wang et al., 2020)

Además de estos métodos que modifican directamente el mecanismo de agregación, se han desarrollado técnicas que introducen una ponderación dinámica basada en el desempeño de los modelos locales. Un ejemplo representativo es FedDF (Lin et al., 2020), que no promedia directamente los parámetros de los modelos locales, sino que emplea un proceso de destilación de conocimiento. En este enfoque, los modelos locales son evaluados utilizando un conjunto de datos auxiliar común (proxy dataset) y su contribución al modelo global se pondera según su rendimiento sobre dicho conjunto. De este modo, los clientes que generan modelos de mayor calidad en términos de precisión, generalización y estabilidad frente a variaciones de datos tienen un mayor impacto en la actualización final. Esta estrategia permite mitigar la influencia de clientes con datos sesgados, de baja calidad, incrementando así la robustez y fiabilidad del modelo agregado en entornos federados heterogéneos.

Otro de los principales retos del aprendizaje federado radica en el elevado coste asociado a la transmisión frecuente de actualizaciones entre los dispositivos participantes y el servidor central. Este intercambio constante de parámetros del modelo, como los pesos o gradientes, puede convertirse en un cuello de botella en escenarios con conectividad limitada, recursos computacionales restringidos o redes móviles donde la transmisión de datos supone un consumo energético elevado. Para mitigar este problema, se han desarrollado técnicas orientadas a reducir el volumen de información transmitida sin comprometer significativamente la calidad del modelo global. Entre las más empleadas se encuentra la cuantización, que reduce la precisión numérica con la que se representan los parámetros del modelo, lo que disminuye el tamaño de los datos enviados, e introduce cierto ruido que debe ser cuidadosamente

gestionado para preservar la estabilidad del entrenamiento. Otra estrategia eficaz es la esparsificación, que consiste en transmitir únicamente una fracción de los gradientes seleccionados en función de su magnitud o relevancia, reduciendo así el tráfico de datos y, en algunos casos, contribuyendo a atenuar el ruido estadístico. Investigaciones como las de Sattler et al. (2019) y Reisizadeh et al. (2020) han evidenciado que estas técnicas pueden conservar niveles de precisión comparables a los alcanzados mediante esquemas de comunicación más intensiva.

4. METODOLOGÍA

Este estudio adopta un enfoque experimental con el objetivo de comparar el entrenamiento federado frente al aprendizaje centralizado. Para ello, se simula un caso de estudio basado en un conjunto de datos clínicos para la detección de la epilepsia, estructurando el proceso en cinco fases principales:

4.1 Selección de los conjuntos de datos y preprocesamiento

Epileptic Seizure Recognition:

El conjunto de datos Epileptic Seizure Recognition proviene originalmente de señales EEG de 23,6 segundos de duración, muestreadas a 173,61 Hz (4.096 puntos por archivo) y procedentes de 500 individuos. Para facilitar las tareas de aprendizaje automático, cada serie completa se dividió en 23 ventanas consecutivas de 1 segundo, compuestas por 178 puntos temporales.

Lo que resultó en un total de 11.500 muestras. La estrategia de generar 23 ventanas por cada señal original fue crucial porque, al dividir cada una de las 500 grabaciones en 23 segmentos de 1 segundo, se logró un aumento significativo en el número de muestras, pasando de 500 a 11.500, lo cual es esencial para entrenar modelos de aprendizaje automático de manera más robusta. Además, esta segmentación en ventanas de 1 segundo permite detectar anomalías de forma más precisa, ya que en un periodo de 23 segundos las características de una crisis epiléptica o cualquier otra anomalía podrían quedar camufladas por la extensión de la señal. Al analizar segmentos más cortos y focales, es posible identificar patrones relevantes con mayor claridad, lo que facilita la clasificación. (Andrzejak et al. (2001))

En su versión original, el dataset contenía cinco clases balanceadas, cada una con 100 registros completos, que tras la segmentación se traducen en 2300 registros por clase.

Cada ventana conserva una etiqueta multicategoría en el rango 1–5: la clase 1 indica crisis epiléptica; la clase 2 EEG procedente de la zona de un tumor; la clase 3 EEG de una región sana en pacientes con tumor; la clase 4 EEG con ojos cerrados y la clase 5

EEG con ojos abiertos. Para la presente investigación, estas cinco categorías se recodificaron en una variable binaria: “crisis epiléptica” (clase 1) frente a “no crisis” (clases 2–5). Esta transformación generó un desequilibrio de clases significativo, ya que la clase “crisis epiléptica” cuenta con 2300 muestras, mientras que la clase “no crisis” agrupa un total de 9200 muestras.

Cada punto dentro de estas ventanas constituye una variable numérica discreta, con valores comprendidos en un rango de -199 (percentil 5) y 544 (percentil 95). Los valores más extremos corresponden a errores de registro que se consideran normales en este tipo de mediciones. No obstante, en este análisis se optó por no eliminarlos, ya que al tratarse de una serie temporal estos registros pueden aportar información relevante sobre la dinámica de la señal. Por ello, se decidió trabajar con todos los datos originales proporcionados en los estudios fundacionales. A continuación, se presenta la distribución de las frecuencias EEG:




Figura 7: Distribución de amplitudes EEG. Fuente: elaboración propia.

4.2 Entorno de desarrollo:

El desarrollo del proyecto se ha realizado en un entorno local utilizando Jupyter Notebook.

El lenguaje utilizado ha sido Python, y las principales librerías empleadas han sido:

- **Scikit-learn**, para el desarrollo de validación y métricas.
- **PyTorch**, para la implementación de modelos personalizados.
- **Pandas**, para la gestión de datos.

- **Matplotlib**, para la visualización de resultados.
- **Flower**, como framework para simular y coordinar el sistema de entrenamiento federado.

4.3 Simulaciones:

En cada simulación se comparan los resultados obtenidos mediante el entrenamiento centralizado estándar y una configuración de entrenamiento federado basado en el algoritmo de agregación FedAvg, utilizando el mismo algoritmo en ambos casos. Según el escenario considerado, la distribución de los datos entre los nodos puede ser más homogénea (IID) o reflejar una mayor heterogeneidad (no-IID), con el fin de evaluar el impacto de distintas condiciones de federación.

La distribución homogénea(IID) se simulará dividiendo el dataset en 10 nodos de forma completamente aleatoria por lo que mantendrán su distribución de probabilidad. Por otro lado, en el caso de la distribución más heterogènia se optó por utilizar el método de muestreo Dirilech, el cual inducirá una heterogeneidad deliberada en las distribuciones de clases a nivel de cada nodo, consiguiendo un escenario más realista de distribución de los datos. Este método se basa en el parámetro α (alfa), un valor alto de este como >1 supondrá distribuciones más homogéneas en cada nodo. En cambio, un α más reducido <1 , generalmente en el rango de 0.1 a 0.5 genera una distribución de clases marcadamente heterogenia(NO-IID). Para esta simulación, se ha elegido un valor de $\alpha=0.5$, esperando obtener una heterogeneidad significativa pero manejable entre los nodos.

A continuación, se muestra la tabla con las distintas simulaciones:

	ALGORITMO	DISTRIBUCIÓN DATOS	FUNCIÓN DE PÉRDIDA
Simulación 1	MLP	IDD	BINARY CROSS ENTROPY
Simulación 2	MLP	no-IDD	BINARY CROSS ENTROPY
Simulación 3	SVM	IDD	HINGE
Simulación 4	SVM	no-IDD	HINGE

Los resultados mostrados para cada simulación se obtienen a partir del promedio de cinco experimentos independientes con el objetivo de garantizar una mayor fiabilidad y representatividad. Para analizar el proceso de aprendizaje de los modelos, se ha representado la evolución de la pérdida y la accuracy tanto en la infraestructura centralizada como en la federada: en el caso centralizado, a lo largo de las épocas, y en el federado, a lo largo de las rondas (5 épocas por ronda). Esta visualización permite estudiar el comportamiento del gap entre entrenamiento y validación, la velocidad de convergencia y la estabilidad de ambos enfoques.

Con el objetivo de que la comparación sea lo más justa posible, se ha establecido una equivalencia entre las 1000 épocas del modelo centralizado y las 200 rondas del modelo federado, dado que en este último cada ronda incluye cinco épocas de entrenamiento local por nodo. Esta configuración se ha elegido deliberadamente como decisión metodológica para reducir la frecuencia de comunicación entre nodos y servidor, minimizando así la carga de conectividad sin comprometer el aprendizaje. Esta equivalencia además permite analizar la velocidad de convergencia de ambos enfoques.

Adicionalmente, para evitar el sobreentrenamiento y optimizar los recursos computacionales, se ha incorporado un mecanismo de early stopping en ambas configuraciones. En el modelo centralizado, el entrenamiento se interrumpe si la pérdida de validación no mejora en 100 épocas consecutivas, mientras que en el modelo federado se detiene si no hay mejora en 20 rondas seguidas, aplicando en ambos casos un umbral mínimo de mejora de $\delta = 1e-4$. En este último caso, todos los nodos

participan de forma constante en cada ronda, simulando una conectividad completa sin interrupciones.

Posteriormente se muestran las matrices de confusión de ambos modelos en el conjunto de test. Para una visualización más clara de las diferencias, se crearon además dos matrices de confusión adicionales: una representando la diferencia absoluta en cada celda entre centralizado y federado (restándolos), y otra con la diferencia porcentual.

Finalmente, para resumir los resultados obtenidos, se presenta una tabla comparativa con las métricas clave de evaluación: accuracy, loss, precision, recall y ROC-AUC. Esta tabla permite observar de forma sintética el rendimiento final de ambos modelos y facilita su interpretación conjunta con las visualizaciones anteriores.

DESCRIPCION MODELO BASE MLP

La siguiente descripción muestra el modelo base que se utiliza para llevar a cabo las simulaciones 1 y 2 basadas en la arquitectura perceptrón multicapa (MLP) para abordar un problema de clasificación binaria.

Arquitectura del modelo

- **Capa de entrada:** 178 neuronas, una por cada variable del conjunto de datos.
- **Capa oculta:** 4 neuronas con función de activación ReLU, que introduce la no linealidad necesaria sin incrementar excesivamente la complejidad computacional.
- **Capa de salida:** 1 neurona con función de activación sigmoide, adecuada para producir una probabilidad asociada a la clase positiva.

Preprocesamiento de datos

1. Se aplica StandardScaler para normalizar cada variable con media cero y desviación estándar unitaria.
2. Se convierten los datos normalizados a tensores.
3. División conjunta en entrenamiento (70 %), validación (15 %) y test (15%)
4. Añadir 32 batches.

Procedimiento de entrenamiento

- **Función de pérdida:** entropía binaria (BCELoss), idónea para medir discrepancias en tareas de clasificación binaria.
- **Optimizador:** Adam con tasa de aprendizaje $\alpha = 0,01$.
- **Épocas máximas:** 1 000 iteraciones sobre el conjunto de entrenamiento.
- **Criterio de parada temprana (early stopping):** se detiene el entrenamiento si la pérdida de validación no mejora en al menos $\Delta = 1 \times 10^{-4}$ durante 100 épocas consecutivas, para prevenir el sobreajuste.




Figura 8. Representación del perceptrón multicapa. Fuente: elaboración propia.

DESCRIPCION MODELO BASE SVM LINEAL (SGD CLASSIFIER CON HINGE)

Preprocesamiento de datos

- Se aplica StandardScaler para normalizar cada variable con media cero y desviación estándar unitaria.
- Se convierten los datos normalizados a tensores.
- División conjunta en entrenamiento (70 %), validación (15 %) y test (15%)

Configuración del modelo SVM

- **Hinge:** Se selecciona la perdida hinge dado que permite trabajar con descenso del gradiente.
- **Ponderación de clases (Class weight):** `class_weight='balanced'`, para contrarrestar la clase minoritaria.
- **Regularización L2 (Weight Decay):** Se aplica una regularización L2 a los pesos del modelo con un valor de $\lambda=0.0005$. Para evitar sobreajuste.
- **Optimizador:** SGD con tasa de aprendizaje fija = 0.01.

5. ANÁLISIS DE RESULTADOS

DATASET EPILEPTIC SEIZURE RECOGNITION

Simulación 1 Centralizado vs Federado IDD en MLP:




Figura 9. Evolución por épocas de Loss y Accuracy. Fuente: elaboración propia.

(Comentario: colores azules representan el entrenamiento centralizado. Azul claro es entrenamiento y azul oscuro validación. En el caso del federado, el rojo es validación y el naranja entrenamiento.)

En la figura 6 la diferencia entre los resultados de entrenamiento y validación es más pronunciada en el caso del modelo federado. En este caso, el federado obtiene mejores resultados durante el entrenamiento, tanto en Loss como en Accuracy, pero en la validación los resultados son ligeramente inferiores a los del modelo centralizado. Esto podría deberse a un posible sobreajuste o a que el modelo no logra capturar correctamente ciertos patrones en los datos de validación. La velocidad de convergencia es similar pero el federado tarda ligeramente menos épocas.




Figura 10. Matrices de confusión modelo centralizado y federado. Fuente: elaboración propia.

Observando las matrices de confusión se aprecia que en ambos casos la mayoría de las predicciones son correctas y verdaderos negativos (i.e 1354 casos en centralizado y 1360 en federado). En el caso de los verdaderos positivos también se predicen de forma satisfactoria. (i.e 280 casos en centralizado y 283 en federado)




Figura 11. Matriz de confusión con la diferencia entre el modelo centralizado y el federado. Fuente: elaboración propia. (Comentario: Las matrices de la figura resultan de restar, celda a celda, la cantidad de ejemplos del modelo federado a los del modelo centralizado. La primera toma la diferencia absoluta y la segunda la diferencia porcentual.

En este caso, las diferencias absolutas entre ambos modelos son mínimas: el modelo federado presenta 17 falsos positivos más que el centralizado, lo que representa un incremento del 20 % respecto a su homólogo. No obstante, este porcentaje adquiere menor relevancia si se considera que el número total de falsos positivos en ambos casos es bajo.

	Accuracy	Loss	Precision	Recall	ROC-AUC
CENTRALIZADO	0.9475	0.1919	0.9164	0.8116	0.9483
FEDERADO IDD	0.9409	0.2333	0.9281	0.7635	0.9388

Tabla 1. Métricas comparativas entre el modelo centralizado y el federado. Fuente: elaboración propia.

Las métricas analizadas evidencian una similitud general entre los enfoques de entrenamiento centralizado y federado; sin embargo, se destaca una disminución del Recall en el modelo federado IDD.

Simulación 2 Centralizado vs Federado NO-IDD en MLP




Figura 9. Evolución por épocas de Loss y Accuracy. Fuente: elaboración propia.
(Comentario: colores azules representan el entrenamiento centralizado. Azul claro es

entrenamiento y azul oscuro validación. En el caso del federado, el rojo es validación y el naranja entrenamiento.

En esta simulación, aunque el rendimiento en entrenamiento es comparable entre ambos escenarios, el modelo federado muestra un desempeño significativamente inferior en la validación respecto al modelo centralizado. Esto sugiere una menor capacidad de generalización y la posible presencia de sobreajuste. Además, destaca la alta inestabilidad en validación del entrenamiento federado.




Figura 12. Matrices de confusión modelo centralizado y federado. Fuente: elaboración propia.

Observando las matrices de confusión se aprecia que el caso más común es el falso negativo en ambos casos, pero ahora el modelo federado no-IDD, obtiene un alto número de falsos positivos (166 casos) casi igualando a los verdaderos positivos (179 casos).




Figura 13. Matriz de confusión con la diferencia entre el modelo centralizado y el federado. Fuente: elaboración propia.

(Comentario: Las matrices de la figura resultan de restar, celda a celda, la cantidad de ejemplos del modelo federado a los del modelo centralizado. La primera toma la diferencia absoluta y la segunda la diferencia porcentual.)

En esta simulación la mayor diferencia absoluta se encuentra en la identificación de los casos positivos, donde el modelo federado obtiene 101 casos más de falsos positivos respecto al centralizado. El equivalente a un 60% más de falsos positivos. En ambos casos hubo muy pocos falsos negativos y por ello, aunque el modelo centralizado tenga solo 19 casos más, esta diferencia supone un incremento del 287%.

	Accuracy	Loss	Precision	Recall	ROC-AUC
CENTRALIZADO	0.9475	0.1919	0.9164	0.8116	0.9483
FEDERADO no-IDD	0.8997	0.7370	0.9697	0.5177	0.8193

Tabla 2. Métricas comparativas entre el modelo centralizado y el federado. Fuente: elaboración propia.

En las métricas comparativas se observa que el modelo federado sin implementación de IDD presenta una pérdida significativamente superior en relación con el modelo centralizado, lo que se refleja en valores más bajos de recall y área bajo la curva ROC (ROC-AUC). No obstante, el modelo federado mantiene elevados niveles de accuracy y

precisión, lo que sugiere un buen desempeño general, aunque con limitaciones en la detección de casos positivos.

Simulación 3. Centralizado SVM vs federado SVM con 10 nodos IDD:




Figura 14. Evolución por épocas de Loss y Accuracy. Fuente: elaboración propia.

(Comentario: colores azules representan el entrenamiento centralizado. Azul claro es entrenamiento y azul oscuro validación. En el caso del federado, el rojo es validación y el naranja entrenamiento.)

Cabe destacar que, en este caso, el modelo centralizado presenta una convergencia más lenta que el federado, a pesar de que su evolución parece mantenerse estancada desde las primeras épocas. En contraste, el modelo federado muestra una mejora progresiva durante las primeras iteraciones. Si bien el rendimiento en ambos indicadores es similar durante la validación de ambos modelos, el comportamiento en el entrenamiento difiere, ya que el modelo federado alcanza resultados notablemente superiores. Esta divergencia podría indicar un posible sobreajuste del modelo federado.




Figura 15. Matrices de confusión modelo centralizado y federado. Fuente: elaboración propia.

En esta simulación ambos modelos detectan la mayoría de los casos en la celda de verdaderos negativos dado que es la clase mayoritaria, pero se obtiene una pésima detección de la clase minoritaria, dado que en ambos hay muchos casos de falsos negativos. El caso del centralizado es extremadamente negativo dado que además obtiene muchos falsos positivos, mostrando que intenta detectar la clase 1 pero muestra dificultades manifiestas.




Figura 16. Matriz de confusión con la diferencia entre el modelo centralizado y el federado. (Comentario: Las matrices de la figura resultan de restar, celda a celda, la cantidad de ejemplos del modelo federado a los del modelo centralizado. La primera

toma la diferencia absoluta y la segunda la diferencia porcentual. Fuente: elaboración propia.

Respecto a las diferencias entre ambos modelos, en el caso de la diferencia de falsos negativos es pequeña, el modelo federado solo obtiene 38 casos más. Mientras que los falsos positivos son mucho más comunes en el centralizado con 285 casos más lo que supone un 619% más que el federado IDD.

	Accuracy	Loss	Precision	Recall	ROC-AUC
CENTRALIZADO	0.7025	0.5001	0.5802	0.4713	0.5177
FEDERADO IDD	0.8454	0.5063	0.7461	0.3606	0.5247

Tabla 3. Métricas comparativas entre el modelo centralizado y el federado. Fuente: elaboración propia.

A primera vista podría interpretarse que el modelo federado actúa como un clasificador más eficaz, dado que alcanza valores superiores de accuracy y precisión. No obstante, la loss y el área bajo la curva ROC (ROC-AUC) resultan prácticamente equivalentes a las del modelo centralizado, lo cual indica que su capacidad de discriminación no es mayor. Tal como se ha observado en las visualizaciones anteriores, este comportamiento sugiere que el modelo federado tiende a priorizar la predicción de la clase mayoritaria, comprometiendo así su rendimiento en la identificación de la clase minoritaria.

Simulación 4. Entrenamiento centralizado SVM vs federado SVM con FedAvg en 10 nodos no-IDD:




Figura 17. Evolución por épocas de Loss y Accuracy. Fuente: elaboración propia.

(Comentario: colores azules representan el entrenamiento centralizado. Azul claro es entrenamiento y azul oscuro validación. En el caso del federado, el rojo es validación y el naranja entrenamiento.)

En este caso el modelo centralizado presenta una convergencia más veloz que el federado, dado que su evolución parece mantenerse estancada desde las primeras épocas. En contraste, el modelo federado muestra una mejora progresiva durante las primeras iteraciones. Si bien el rendimiento en ambos indicadores es similar durante la validación de ambos modelos, el comportamiento en el entrenamiento difiere, ya que el modelo federado alcanza resultados notablemente superiores. Esta divergencia podría indicar un posible sobreajuste del modelo federado.




Figura 18. Matrices de confusión modelo centralizado y federado. Fuente: elaboración propia.

En esta simulación ambos modelos detectan la mayoría de los casos en la celda de verdaderos negativos dado que es la clase mayoritaria, pero se obtiene una pésima detección de la clase minoritaria, dado que en ambos hay muchos casos de falsos negativos. El caso del centralizado es extremadamente negativo dado que además obtiene muchos falsos positivos, mostrando que intenta detectar la clase 1 pero muestra dificultades manifiestas.




Figura 19. Matriz de confusión con la diferencia entre el modelo centralizado y el federado. Fuente: elaboración propia. (Comentario: Las matrices de la figura resultan de restar, celda a celda, la cantidad de ejemplos del modelo federado a los del modelo centralizado. La primera toma la diferencia absoluta y la segunda la diferencia porcentual.

Respecto a las diferencias entre ambos modelos, en el caso de la diferencia de falsos negativos es pequeña, el modelo federado solo obtiene 38 casos más. Mientras que los falsos positivos son mucho más comunes en el centralizado con 285 casos más lo que supone un 350% más que el federado no-IDD.

	Accuracy	Loss	Precision	Recall	ROC-AUC
CENTRALIZADO	0.7025	0.5001	0.5802	0.4713	0.5177
FEDERADO NO-IDD	0.8384	0.4924	0.6692	0.4046	0.5571

Tabla 4. Métricas comparativas entre el modelo centralizado y el federado. Fuente: elaboración propia.

Los indicadores revelan que el modelo federado NO-IDD exhibe valores superiores de accuracy y precisión. Sin embargo, es fundamental notar que la función de pérdida (loss) y el área bajo la curva ROC (ROC-AUC) resultan prácticamente equivalentes a las del modelo centralizado. Esta similitud en estas métricas es indicativa de que la capacidad de discriminación general del modelo federado no es intrínsecamente superior.

Consistentemente con el modelo federado IDD, este comportamiento sugiere una tendencia del modelo federado a priorizar la predicción de la clase mayoritaria. Esta inclinación compromete, su rendimiento en la identificación de la clase minoritaria. La equivalencia en los valores de loss y ROC-AUC, a pesar de las ganancias en accuracy y precisión, subraya que las mejoras se concentran en la clase dominante, enmascarando la dificultad para clasificar la clase minoritaria de manera efectiva en este escenario.

6. CONSIDERACIONES ÉTICAS

Durante el proyecto se ha visto como el aprendizaje federado no es solo otro método, sino una alternativa estratégica al entrenamiento centralizado que vela por la seguridad y privacidad de los datos de usuarios en un contexto cada vez más marcado por el aumento del volumen de datos, las preocupaciones sobre el uso indebido y la ciberseguridad.

La posibilidad de entrenar modelos sin necesidad de centralizar los datos representa un avance no solo técnico, sino también ético, salvaguarda la privacidad, situándose en la línea del cumplimiento del marco legal europeo como el GDPR, el Data Governance act y el Data Act. Todas estas leyes tienen un trasfondo ético común: el respeto por los ciudadanos y su derecho a decidir sobre los datos que producen.

A ello se suman los avances que supone en equidad y no discriminación: al facilitar el acceso a nuevas fuentes de datos alternativas, se permite capturar una mayor diversidad de contextos, lo cual contribuye a reducir los sesgos propios de los datasets centralizados. Sin embargo, es importante reconocer que el aprendizaje federado, al igual que cualquier sistema de aprendizaje automático, no es inmune a los sesgos. La equidad sigue siendo una preocupación central, ya que los modelos pueden reflejar y amplificar los sesgos inherentes a los datos de entrenamiento. En un entorno federado, el control sobre la calidad y representatividad de los datos en cada nodo cliente puede ser un desafío. Si los datos de ciertos grupos demográficos son escasos o están subrepresentados, el modelo global podría obtener un rendimiento inferior para esos grupos, conduciendo a un sesgo algorítmico que podría afectar de manera desproporcionada a ciertos colectivos.

Otro de los mayores riesgos éticos en el aprendizaje federado es la corresponsabilidad de los múltiples actores involucrados en el entrenamiento del modelo. A diferencia del entrenamiento centralizado, donde la responsabilidad recae en una sola entidad, el entrenamiento federado distribuye esta carga. Es crucial establecer un marco claro de rendición de cuentas para determinar quién es responsable en caso de que el modelo cause daños, como decisiones discriminatorias o violaciones de la privacidad. La falta

de un marco de responsabilidad bien definido podría dificultar la reparación y la supervisión, diluyendo la responsabilidad y facilitando posibles abusos.

Por otro lado, el aprendizaje federado tiene el potencial de ser un factor disruptivo en el desarrollo de la IA. Al no requerir la centralización de los datos, permite que organizaciones más pequeñas, que anteriormente carecían de la infraestructura para manejar grandes volúmenes de datos centralizados, puedan participar en el ecosistema de la IA, fomentando una mayor competencia.

7. DISCUSIÓN

En este estudio, las simulaciones han revelado diferencias significativas tanto en el rendimiento como en la dinámica de convergencia entre los modelos de aprendizaje centralizado y federado, utilizando modelos de Red Neuronal Multicapa (MLP) Máquinas de Vectores de Soporte (SVM).

Se observó que el modelo MLP alcanzó una predicción notablemente satisfactoria, con un ROC-AUC aproximado de 0.900. En este escenario, el modelo centralizado consistentemente superó a sus contrapartes federadas. Además, dentro de los modelos federados, el enfoque IID (independiente e idénticamente distribuido) mostró un rendimiento superior al NO-IID (no independiente e idénticamente distribuido). Este patrón se alinea consistentemente con las expectativas generales de la literatura en aprendizaje federado, donde la heterogeneidad de los datos suele representar un desafío considerable (McMahan et al., 2017).

Además, se observó una marcada inestabilidad en el modelo MLP federado bajo una distribución NO-IID, lo cual es coherente con los hallazgos previos al utilizar el algoritmo de agregación FedAvg (Zhao et al., 2018). Esta inestabilidad se explica por la ausencia de mecanismos de control en FedAvg para abordar el sesgo inducido por la heterogeneidad de los datos locales. En contextos NO-IID, donde cada cliente dispone de distribuciones de datos significativamente distintas, las actualizaciones locales tienden a divergir en direcciones inconsistentes. La agregación directa de estos modelos divergentes puede provocar oscilaciones en los parámetros globales o la convergencia hacia soluciones subóptimas, lo cual se traduce en un comportamiento más errático del modelo en comparación con escenarios IID.

Por otro lado, el modelo SVM presentó un rendimiento más modesto, con un ROC-AUC cercano a 0.5100, lo que indica una capacidad predictiva muy limitada y prácticamente equivalente a una clasificación aleatoria. Curiosamente, en este caso, las diferencias de rendimiento entre el modelo centralizado y el federado fueron mínimas, e incluso el modelo federado obtuvo resultados ligeramente superiores. Un hallazgo destacable es que el modelo federado NO-IID alcanzó el mejor resultado para SVM

con un ROC-AUC de 0.5571, lo cual contradice la expectativa de que el rendimiento NO-IDD siempre sería inferior. Este resultado particular con el modelo SVM sugiere que la distribución No-IDD no siempre conduce a los peores rendimientos. Se hipotetiza que esto podría deberse a la incapacidad inherente del SVM lineal para captar correctamente las relaciones subyacentes en el conjunto de datos, lo que potencialmente enmascararía el impacto negativo de la heterogeneidad. Esta limitación podría ser resultado de que las categorías no sean separables linealmente. Adicionalmente, otra posibilidad es que el SVM se haya sesgado dada la distribución desbalanceada de clases, un fenómeno al que este algoritmo es particularmente sensible, sobre todo si no está perfectamente configurado el umbral de decisión y el learning rate (Rezvani et al.,2024).

En cuanto al ritmo de convergencia, el entrenamiento federado NO-IDD demostró ser generalmente más lento en todas las simulaciones. Mientras que el entrenamiento federado IDD obtenía una convergencia superior a la del modelo centralizado.

Dentro de los errores de predicción, predominaron los falsos negativos en la mayoría de los modelos, con la excepción notable del SVM centralizado, que arrojó un mayor número de falsos positivos. Esta norma se justifica debido a que la clase mayoritaria negativa puede sesgar los resultados, llevando al algoritmo a priorizar la predicción de esta clase sobre la minoritaria, lo que se refleja en el bajo rendimiento general del modelo en la tarea de clasificación.

En todos los casos de entrenamiento federado, la diferencia entre los resultados de entrenamiento y los de validación fue superior a la del caso centralizado, lo que demuestra que estos problemas de generalización no se deben al desbalance de clases propio de la configuración NO-IID, sino a otros factores inherentes al propio proceso de entrenamiento federado.

8. PLAN DE TRABAJO Y COSTE ECONÓMICO

8.1 Plan de Trabajo

- Conocimiento del dominio: Se realizarán reuniones con T-Systems para comprender el contexto y el dominio. Además, se realizará una búsqueda bibliográfica para ampliar el conocimiento del campo. 46 horas
- Estudio de técnicas a implementar: Se valorará que técnicas de machine learning son apropiadas y como adaptarlas para la comparación entre modelos. 30 horas
- Preparación de los datos: 16 horas
 - Tratamiento de nulos e incoherencias
 - Creación de nuevas variables
- Aplicación de las técnicas y obtención de resultados: Se estudiará la documentación de las librerías especializadas para el entrenamiento federado y se crearán métricas para comparar los enfoques. 50 horas
- Redacción informe: El informe se realizará de forma progresiva y se hará una revisión final para revisar la coherencia entre cada una de las partes. 50 horas

Las tarifas a aplicar para el coste del proyecto se basan en las recomendaciones de mi tutor que desarrolla su actividad profesional en el mundo empresarial dirigiendo proyectos afines a la temática desarrollada en una empresa muy implantada en el sector.

El coste por hora de mi rol Junior sería de 30€/hora y las horas de reunión y corrección correspondientes al manager se deben agregar con un coste de 85€/hora.

8.2 Coste económico

TABLA DEL COSTE/COBRO

TAREA	Junior (30 €/h)	Manager (85 €/h)	Total horas	Coste total (€)
Conocimiento del dominio	30 horas	16 horas	46 horas	2.260 €
Estudio de técnicas a implementar	30 horas	0 horas	30 horas	900 €
Preparación de los datos	16 horas	0 horas	16 horas	480 €
Aplicación de las técnicas y obtención de resultados	50 horas	0 horas	50 horas	1.500 €
Redacción informe	50 horas	0 horas	50 horas	1.500 €
TOTAL	176 horas	16 horas	192 horas	5.960 €

9. CONCLUSIONES

En este estudio se han comparado modelos centralizados y federados, evaluando tanto su rendimiento como su dinámica de convergencia en entornos IID y No-IID. Los resultados han puesto de manifiesto los siguientes retos:

- El rendimiento del entrenamiento federado en los modelos cuyos resultados no son aleatorios (ver apartado discusión) es inferior al centralizado tanto en escenarios IDD como NO-IDD. Destacando la reducción en el caso de los escenarios NO-IDD.
- El entrenamiento federado ha mostrado una menor capacidad de generalización ya que se observa un mayor diferencial entre sus resultados de entrenamiento y validación en comparación con el modelo centralizado.
- La falta de generalización parece no ser consecuencia directa de la heterogeneidad entre la distribución de clases entre nodos.
- La falta de homogeneidad en la distribución de los datos en nodos muestra una tendencia a una convergencia más lenta que aquellos con una distribución homogénea o el entrenamiento centralizado. Por lo tanto, el coste económico para alcanzar el óptimo de entrenamientos es más alto en la aproximación NO-IDD.
- En el entrenamiento federado parece existir un sesgo superior en la clase mayoritaria.

10. LÍNEAS DE FUTURO

A partir del trabajo realizado, se identifican varias direcciones que podrían explorarse en investigaciones futuras:

- Probar nuevos algoritmos de agregación para ver si mejoran el rendimiento del entrenamiento federado.
- Buscar estrategias para mejorar la generalización de los modelos con metodología federada.
- Investigar cómo mejorar la convergencia en los escenarios federados NO-IDD.
- Explorar técnicas de balanceo de datasets para resolver el sesgo superior en la clase mayoritaria en el entrenamiento federado.
- Probar otras configuraciones de algoritmos para comprobar como varia el rendimiento.

11. BIBLIOGRAFÍA

Andrzejak RG, Lehnertz K, Rieke C, Mormann F, David P, Elger CE (2001) Indications of nonlinear deterministic and finite dimensional structures in time series of brain electrical activity: Dependence on recording region and brain state, *Phys. Rev. E*, 64, 061907

Chen, D., Gao, D., Xie, Y., Pan, X., Li, Z., Li, Y., Ding, B., & Zhou, J. (2023). FS-REAL: Towards real-world cross-device federated learning.

Comisión Europea. (2023). Una estrategia europea de datos. <https://digital-strategy.ec.europa.eu/es/policies/strategy-data>

Comisión Europea. (2017). *European Interoperability Framework – Implementation Strategy*. <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX%3A52017DC0134>

Data Spaces Support Centre (DSSC). (2024). Data Spaces Blueprint. <https://dssc.eu/space/bv15e/766061169/Data%2BSpaces%2BBlueprint%2Bv1.5%2B-%2BHome>

EuroHPC JU (2025) AI GigaFactories - Workshop Presentation - 22 May 2025
https://eurohpc-ju.europa.eu/public-consultation-ai-gigafactories-2025-04-09_en

Finck, M., & Pallas, F. (2020). They who must not be identified—Distinguishing personal from non-personal data under the GDPR. *International Data Privacy Law*, 10(1), 11–36. <https://doi.org/10.1093/idpl/ipz026>

Gaia-X European Association for Data and Cloud AISBL. (2024, 10 de mayo). Gaia-X Architecture Document (Version 24.04).

GAIA-X Hub Austria. (2023). Building a Dataspace: Technical Overview.

Gieß, A., Hupperz, M. J., Schoormann, T., & Möller, F. (2024). What does it take to connect? Unveiling characteristics of data space connectors. <https://scholarspace.manoa.hawaii.edu/items/37a20d71-8c45-4f4b-9518-2c5176802457>

Google. (n.d.). Clasificación: ROC y AUC. Google Developers. Recuperado 25 de Julio de 2025, de <https://developers.google.com/machine-learning/crash-course/classification/roc-and-auc?hl=es-419>

Gorbett, M., Shirazi, H., & Ray, I. (2024). Cross-Silo Federated Learning Across Divergent Domains with Iterative Parameter Alignment.

Hartmann, Maria & Danoy, Grégoire & Alswaitti, Mohammed & Bouvry, Pascal. (2023). JoVe-FL: A Joint-Embedding Vertical Federated Learning Framework. 416-426. 10.5220/0011802600003393.

IDSA (International Data Spaces Association) (2019). Reference Architecture Model (Version 3.0).

James, G., Witten, D., Hastie, T. y Tibshirani, R. (2013). An Introduction to Statistical Learning, Springer. Capítulo "Support Vector Machines".

Kairouz, P., McMahan, H. B., Avent, B., Bellet, A., Bennis, M., Bhagoji, A. N., ... & Zhao, S. (2021). *Advances and open problems in federated learning*. *Foundations and Trends in Machine Learning*, 14(1–2), 1–210. <https://doi.org/10.1561/22000000083>

Li, J., Chen, H., Dong, Q., Chen, J., & Chen, Y. (2021). Demand forecasting of e-commerce enterprises based on horizontal federated learning from the perspective of sustainable development. *Sustainability*, 13(23), 13050. <https://doi.org/10.3390/su132313050>

Li, T., Sahu, A. K., Zaheer, M., Sanjabi, M., Talwalkar, A., & Smith, V. (2020). Federated optimization in heterogeneous networks.

Lin, T., Kong, L., Stich, S. U., & Jaggi, M. (2020). Ensemble Distillation for Robust Model Fusion in Federated Learning. En Proceedings of the 34th Conference on Neural Information Processing Systems (NeurIPS 2020).

Liu, Y., Zhang, X., & Wang, L. (2020). Asymmetrical vertical federated learning.

Lu, Y., Huang, X., Zhang, K., Maharjan, S., & Zhang, Y. (2021). Communication-Efficient Federated Learning for Digital Twin Edge Networks in Industrial IoT. *IEEE Transactions on Industrial Informatics*. <https://doi.org/10.1109/TII.2020.3010798>

Manzoor, H.U.; Shabbir, A.; Chen, A.; Flynn, D.; Zoha, A. A Survey of Security Strategies in Federated Learning: Defending Models, Data, and Privacy. *Future Internet* 2024, 16, 374. <https://doi.org/10.3390/fi16100374>

McMahan, H. B., Moore, E., Ramage, D., Hampson, S., & Agüera y Arcas, B. (2023). Communication-efficient learning of deep networks from decentralized data.

National Institute of Standards and Technology (NIST). (2020). *An Introduction to Information Security (SP 800-12 Rev. 1)*. <https://csrc.nist.gov/publications/detail/sp/800-12/rev-1/final>

Otto, Boris (2011) "Data Governance," *Business & Information Systems Engineering*: Vol. 3: Iss. 4, 241-244. DOI 10.1007/s12599-011-0162-8

Qiang Yang, Yang Liu, Tianjian Chen, and Yongxin Tong. 2019. Federated Machine Learning: Concept and Applications. *ACM Trans. Intell. Syst. Technol.* 10, 2, Article 12 (February 2019), 19 pages. <https://doi.org/0000001.0000001>

Reisizadeh, A., Mokhtari, A., Hassani, H., Jadbabaie, A., & Pedarsani, R. (2020). FedPAQ: A Communication-Efficient Federated Learning Method with Periodic Averaging and Quantization. En Proceedings of the 23rd International Conference on Artificial Intelligence and Statistics (AISTATS).

Rezvani et al. (2024) Methods for Class-Imbalanced Learning with Support Vector Machines: A Review and an Empirical Evaluation

Sattler, F., Wiedemann, S., Müller, K.-R., & Samek, W. (2020). Robust and Communication-Efficient Federated Learning From Non-i.i.d. Data. IEEE Transactions on Neural Networks and Learning Systems, 31(9)

Sellami, M., Bueno Momčilović, T., Kuhn, P., & Balta, D. (2023). *Interaction patterns for regulatory compliance in federated learning*. In *Proceedings of the International Workshop on Data Spaces – State of Play, Challenges and Prospects* (pp. 1–7). CEUR Workshop Proceedings, 3512. <https://ceur-ws.org/Vol-3512/fullpaper1.pdf>

Unión Europea. (2022). Reglamento (UE) 2022/868 del Parlamento Europeo y del Consejo, de 30 de mayo de 2022, relativo a la gobernanza europea de datos y por el que se modifica el Reglamento (UE) 2018/1724 (Ley de Gobernanza de Datos). Diario Oficial de la Unión Europea, L 152/1.

Unión Europea. (2023). Reglamento (UE) 2023/2854 del Parlamento Europeo y del Consejo, de 13 de diciembre de 2023, sobre normas armonizadas para un acceso justo a los datos y un uso de datos no discriminatorio, y por el que se modifican los Reglamentos (UE) n.º 1286/2014 y (UE) 2020/1706 y la Directiva (UE) 2020/1828 (Ley de Datos). Diario Oficial de la Unión Europea, L, 2023/2854.

Veale, M., & Zuiderveen Borgesius, F. (2021). Demystifying the Draft EU Artificial Intelligence Act: Analysing the good, the bad, and the unclear elements of the proposed approach. Computer Law Review International, 22(4), 97–112. <https://doi.org/10.9785/cr-2021-220402>

Wang, J., Liu, Q., Liang, H., Joshi, G., & Poor, H. V. (2020). Tackling the objective inconsistency problem in heterogeneous federated optimization.

Xu, J., Glicksberg, B. S., Su, C., Walker, P., Bian, J., & Wang, F. (2021). Federated Learning for Healthcare Informatics. *Journal of Healthcare Informatics Research*, 5, 1-19. <https://doi.org/10.1007/s41666-020-00082-4>

Zhang, J., Hua, Y., Wang, H., Song, T., Xue, Z., Ma, R., Cai, J., & Guan, H. (2023). GPFL: Simultaneously learning global and personalized feature information for personalized federated learning.

Zhao, Y., Li, M., Lai, L., Suda, N., Civin, D., & Chandra, V. (2018). Federated Learning with Non-IID Data. Karimireddy, S. P., Kale, S., Mohapatra, G., Reddi, V. J., & Stich, S. (2020). SCAFFOLD: Stochastic Controlled Averaging for Federated Learning. In *International Conference on Machine Learning (ICML)*.

Zillner, S., Gomez, J. A., García Robles, A., Hahn, T., Le Bars, L., Petkovic, M., & Curry, E. (2020). Data economy 2.0: From big data value to AI value and a European data space. *Applied Sciences*, 10(22), 7752. <https://doi.org/10.3390/app10227752>